ECOLE MAROCAINE DES SCIENCES DE L'INGENIEUR
Membre de HONORIS UNITED UNIVERSITIES

# DEEP LEARNING: 102


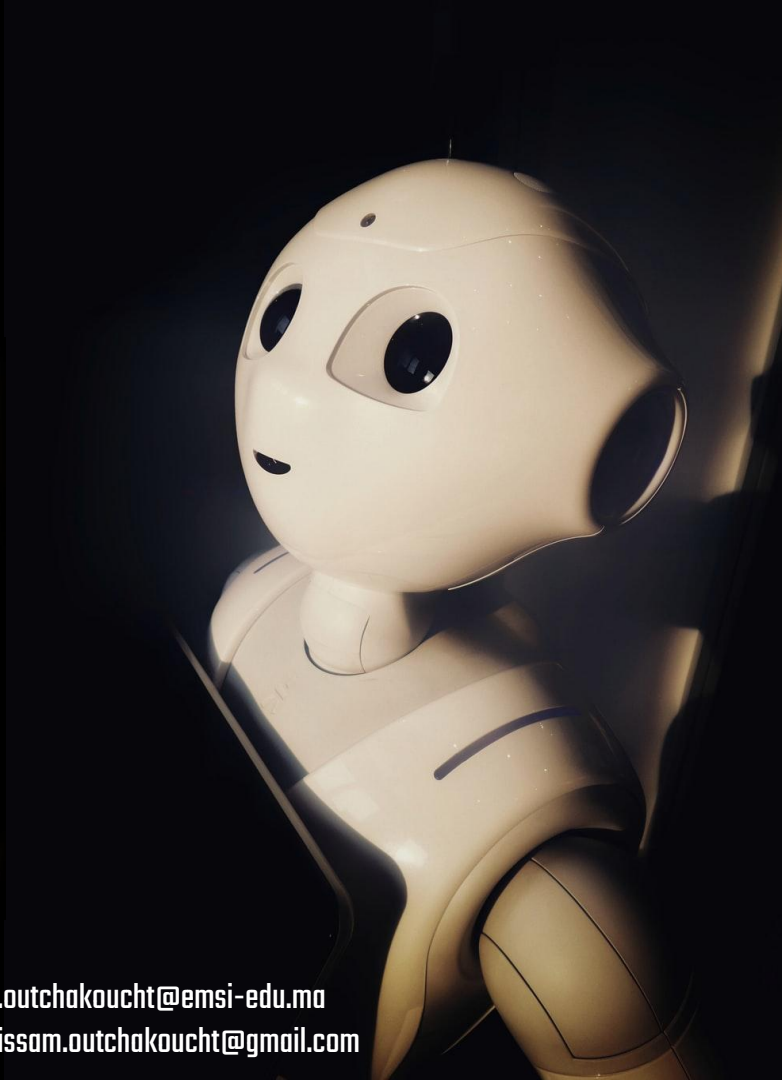

Aissam Outchakoucht

a.outchakoucht@emsi-edu.ma
aissam.outchakoucht@gmail.com

# RECAP

L'apprentissage profond est très pratique quand il s'agit de

## Problèmes complexes

tels que la classification des images, le traitement du langage naturel et la reconnaissance vocale.

# RECAP

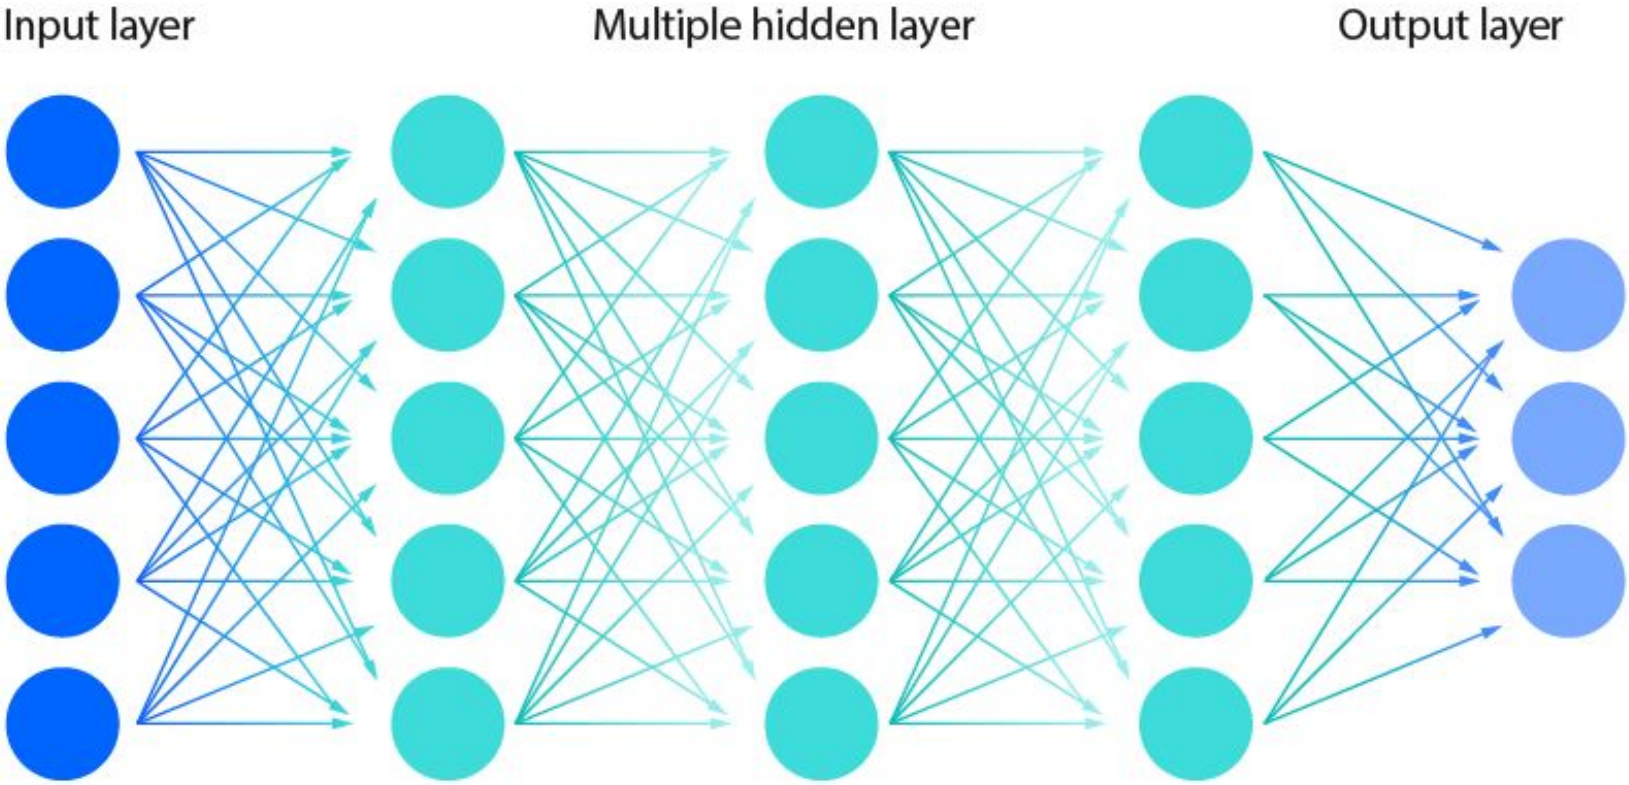

# RECAP

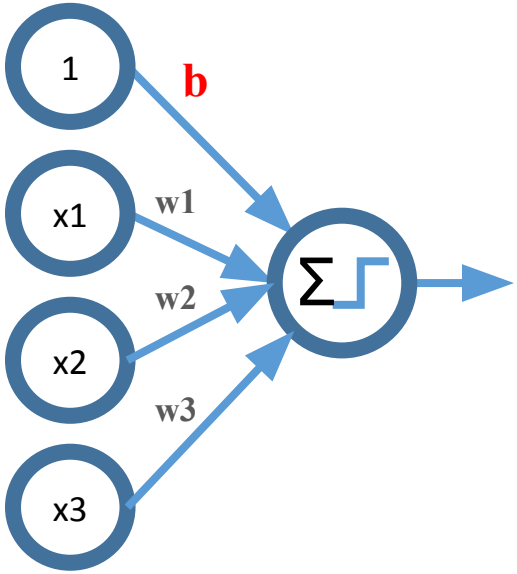


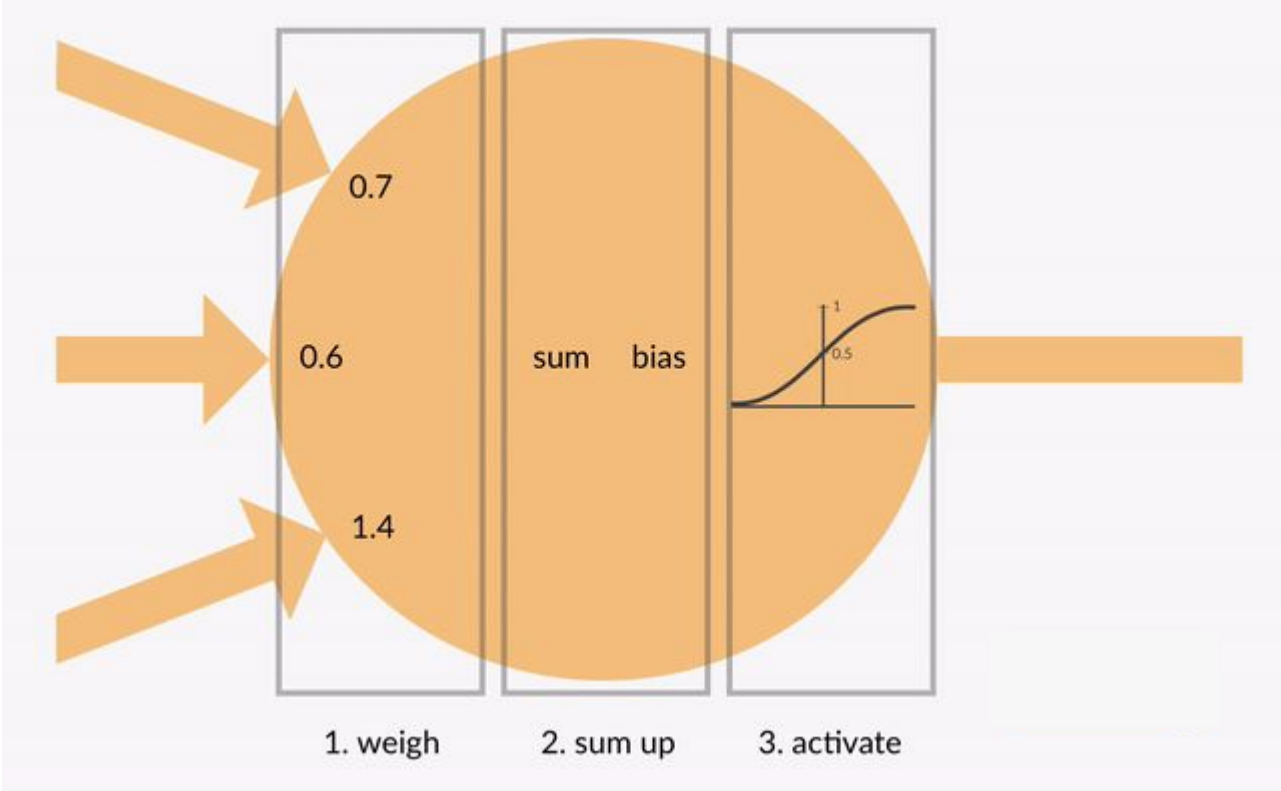


$F(x) = \sigma(\ W\ .X + b\ )$

# RECAP.py

```
# Chargement des données
(X_train, y_train), (X_test, y_test) = mnist.load_data()
```

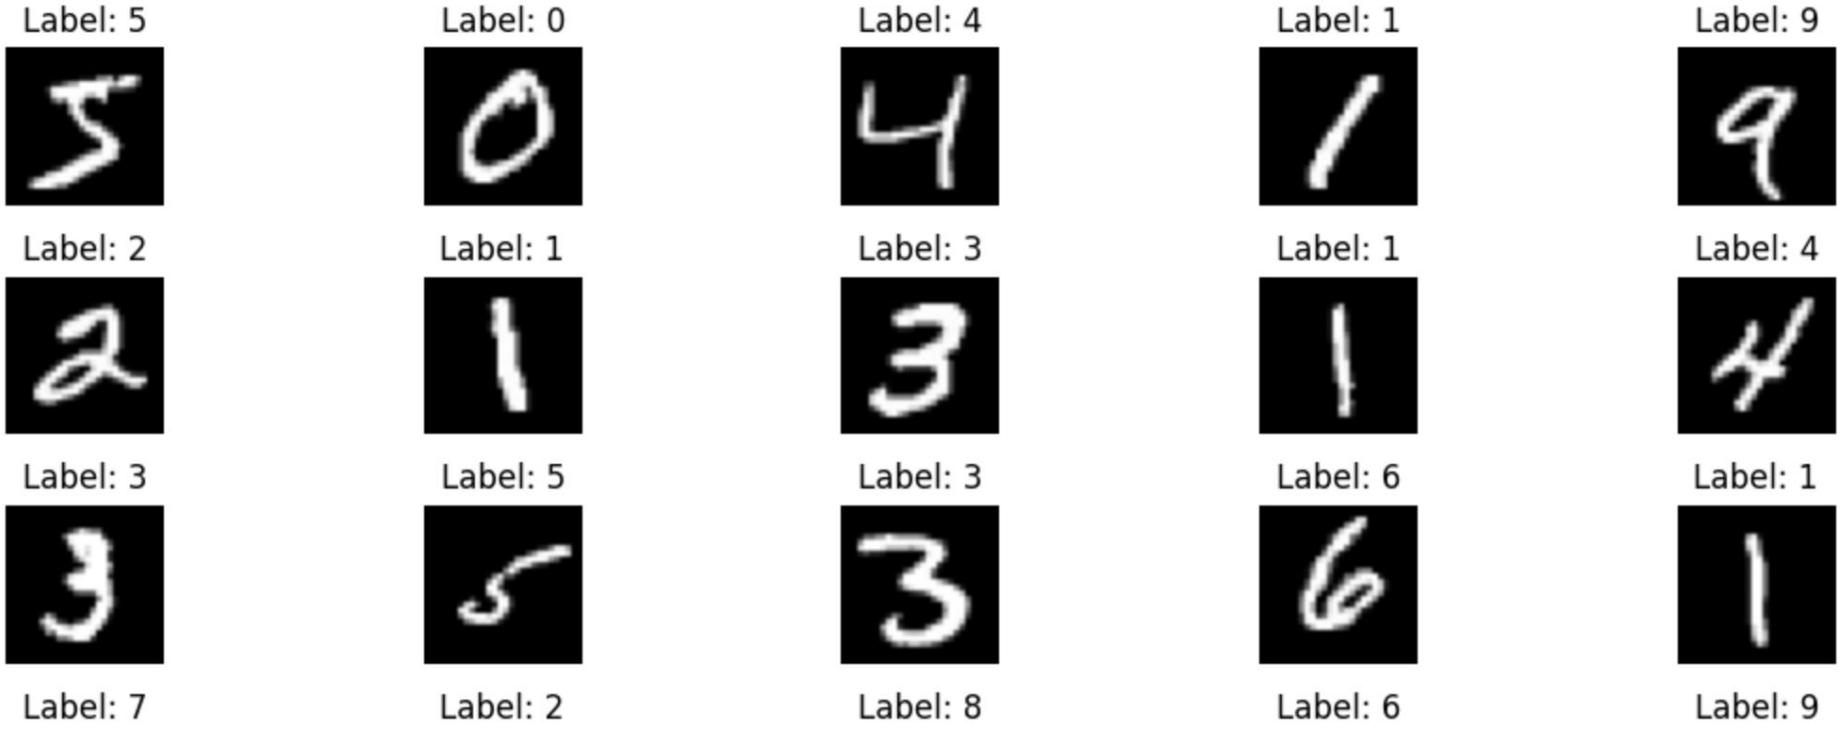

# RECAP.py

```python
model = Sequential([
    Flatten(input_shape=(28,28)),        # Aplatit les images 28x28 en vecteurs de 784 éléments
    Dense(128, activation='relu'),       # Couche cachée avec 128 neurones et activation ReLU
    Dense(10, activation='softmax')      # Couche de sortie avec 10 neurones (une pour chaque classe)
])
```

```python
model.compile(optimizer='adam', loss='categorical_crossentropy', metrics=['accuracy'])
```

```python
# Entraînement du Modèle
history = model.fit(X_train, y_train, epochs=10, validation_split=0.1)
```

```
Epoch 1/10
1688/1688 ━━━━━━━━━━━━━━━━━━━━ 6s 3ms/step - accuracy: 0.8681 - loss: 0.4688 - val_accuracy: 0.9622 - val_loss: 0.1281
Epoch 2/10
1688/1688 ━━━━━━━━━━━━━━━━━━━━ 7s 4ms/step - accuracy: 0.9623 - loss: 0.1299 - val_accuracy: 0.9730 - val_loss: 0.0940
Epoch 3/10
1688/1688 ━━━━━━━━━━━━━━━━━━━━ 5s 3ms/step - accuracy: 0.9747 - loss: 0.0850 - val_accuracy: 0.9730 - val_loss: 0.0933
Epoch 4/10
1688/1688 ━━━━━━━━━━━━━━━━━━━━ 12s 4ms/step - accuracy: 0.9804 - loss: 0.0635 - val_accuracy: 0.9762 - val_loss: 0.0811
Epoch 5/10
1688/1688 ━━━━━━━━━━━━━━━━━━━━ 5s 3ms/step - accuracy: 0.9862 - loss: 0.0457 - val_accuracy: 0.9777 - val_loss: 0.0760
Epoch 6/10
1688/1688 ━━━━━━━━━━━━━━━━━━━━ 10s 3ms/step - accuracy: 0.9900 - loss: 0.0351 - val_accuracy: 0.9745 - val_loss: 0.0838
Epoch 7/10
1688/1688 ━━━━━━━━━━━━━━━━━━━━ 10s 3ms/step - accuracy: 0.9916 - loss: 0.0288 - val_accuracy: 0.9757 - val_loss: 0.0860
Epoch 8/10
1688/1688 ━━━━━━━━━━━━━━━━━━━━ 6s 3ms/step - accuracy: 0.9937 - loss: 0.0215 - val_accuracy: 0.9807 - val_loss: 0.0709
```

# RECAP.py

```
# Prédictions
y_pred = model.predict(X_test)
```

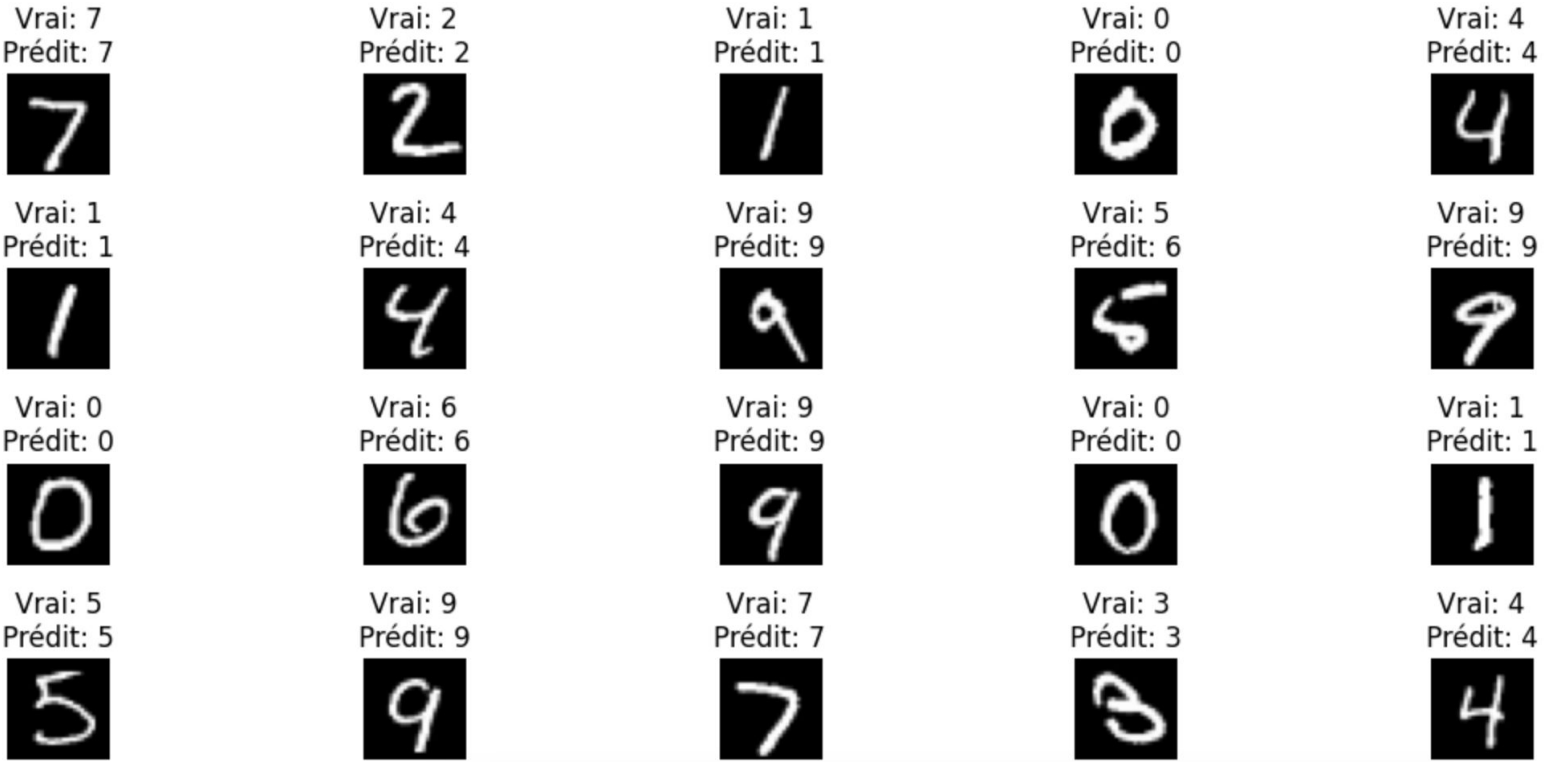

# RECAP.py

```python
# Early Stopping
early_stop = EarlyStopping(monitor='val_loss', patience=3)

# Modèle avec Early Stopping
model_early_stop = Sequential([
    Flatten(input_shape=(28,28)),
    Dense(512, activation='relu'),
    Dense(256, activation='relu'),
    Dense(128, activation='relu'),
    Dense(64, activation='relu'),
    Dense(10, activation='softmax')
])

model_early_stop.compile(optimizer='adam', loss='categorical_crossentropy', metrics=['accuracy'])

# Entraînement du modèle
history_early_stop = model_early_stop.fit(X_train, y_train, epochs=50, validation_split=0.1, callbacks=[early_stop])
```

```
Epoch 1/50
1688/1688 ━━━━━━━━━━━━━━━━━━━━ 18s 10ms/step - accuracy: 0.8832 - loss: 0.3751 - val_accuracy: 0.9687 - val_loss: 0.1075
Epoch 2/50
1688/1688 ━━━━━━━━━━━━━━━━━━━━ 20s 10ms/step - accuracy: 0.9700 - loss: 0.0995 - val_accuracy: 0.9748 - val_loss: 0.0890
Epoch 3/50
1688/1688 ━━━━━━━━━━━━━━━━━━━━ 16s 10ms/step - accuracy: 0.9794 - loss: 0.0666 - val_accuracy: 0.9800 - val_loss: 0.0687
Epoch 4/50
1688/1688 ━━━━━━━━━━━━━━━━━━━━ 16s 10ms/step - accuracy: 0.9836 - loss: 0.0523 - val_accuracy: 0.9762 - val_loss: 0.0857
Epoch 5/50
1688/1688 ━━━━━━━━━━━━━━━━━━━━ 16s 10ms/step - accuracy: 0.9877 - loss: 0.0419 - val_accuracy: 0.9788 - val_loss: 0.0776
Epoch 6/50
1688/1688 ━━━━━━━━━━━━━━━━━━━━ 17s 10ms/step - accuracy: 0.9889 - loss: 0.0364 - val_accuracy: 0.9818 - val_loss: 0.0699
```

# RECAP.ppt

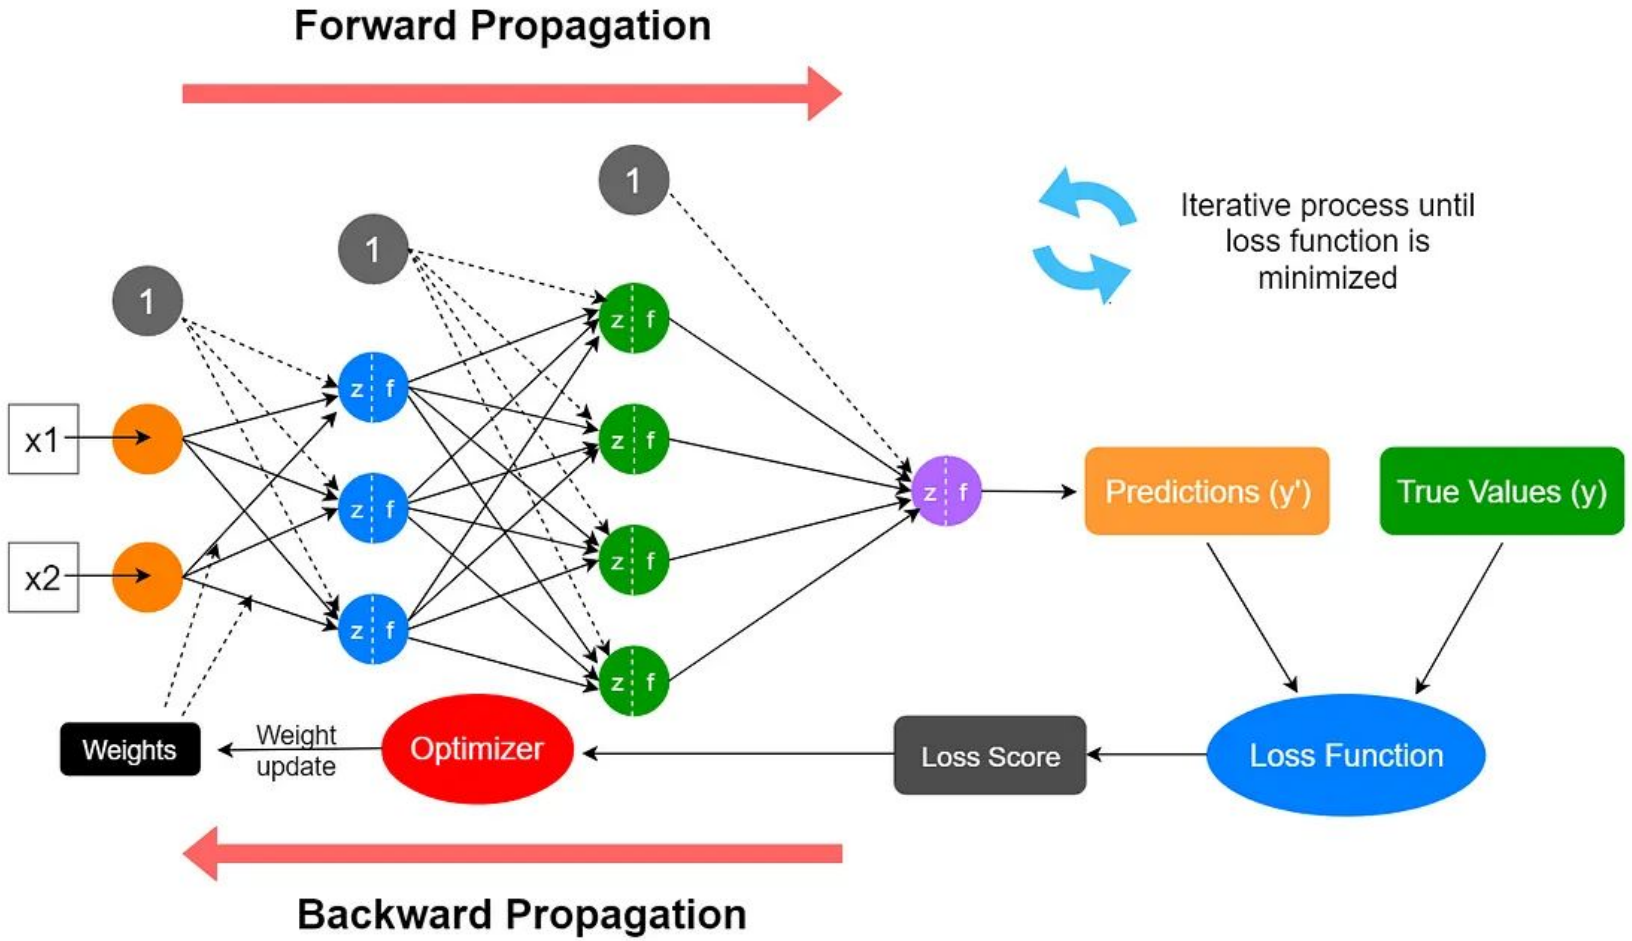
Forward Propagation
1
1
1
x1
x2
z f
z f
z f
z f
z f
z f
z f
Iterative process until loss function is minimized
Predictions (y')
True Values (y)
Loss Function
Loss Score
Optimizer
Weight update
Weights
Backward Propagation

# RECAP

**Hypothèse :**

$$f(x) = a \cdot x + b$$

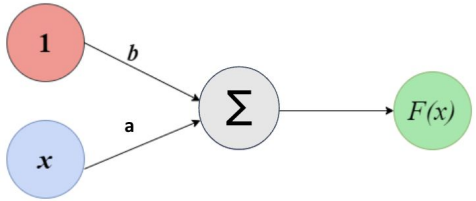


**Paramètres :**

$$a, b$$

**Fonction Coût :**

$$J(a,b) = \frac{1}{2m} \sum_{i=1}^{m} \left( f(x^{(i)}) - y^{(i)} \right)^2$$

**Objectif :**

$$\min_{a,b} J(a,b)$$

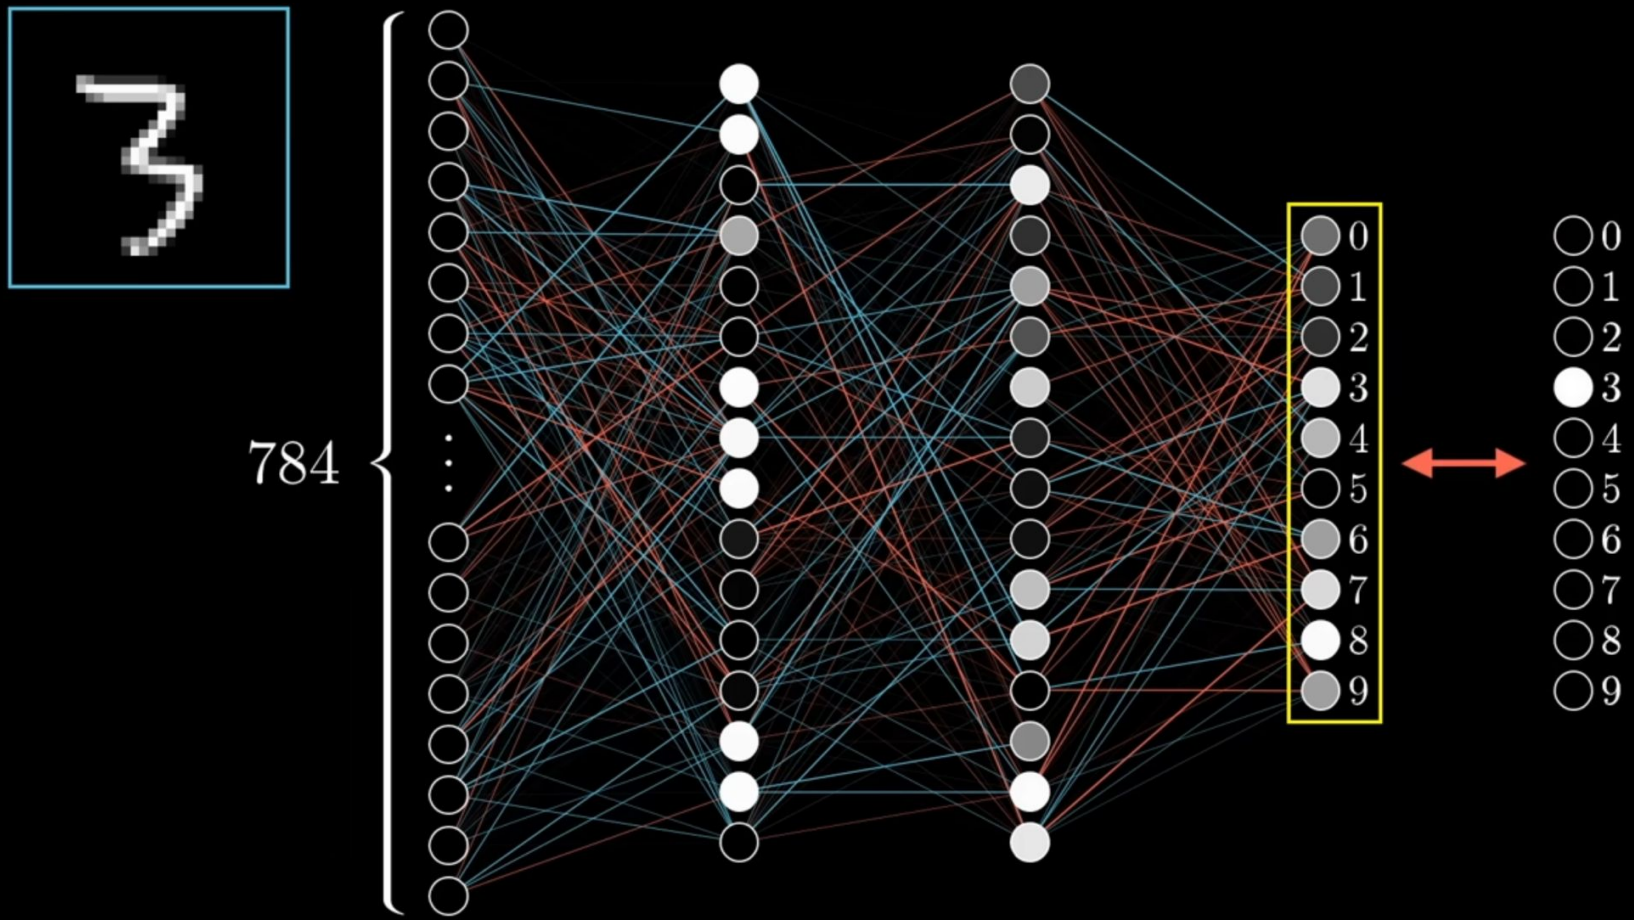
784
0
1
2
3
4
5
6
7
8
9
0
1
2
3
4
5
6
7
8
9

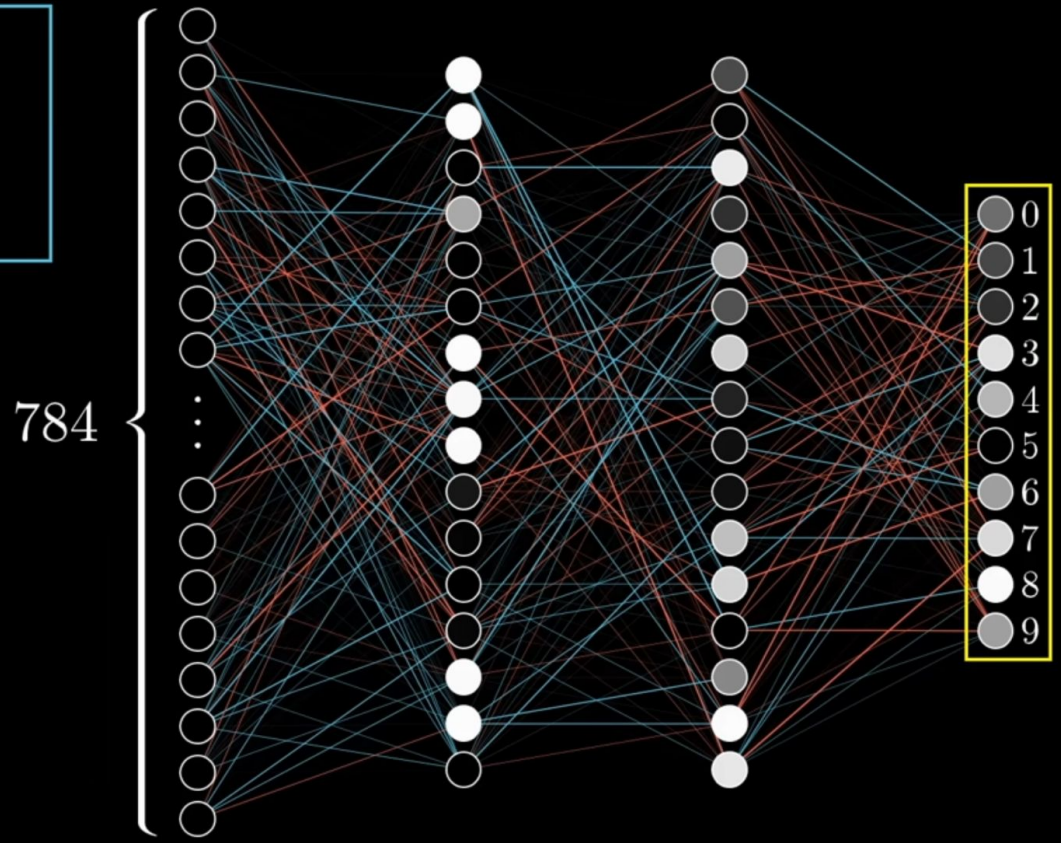
784
0
1
2
3
4
5
6
7
8
9

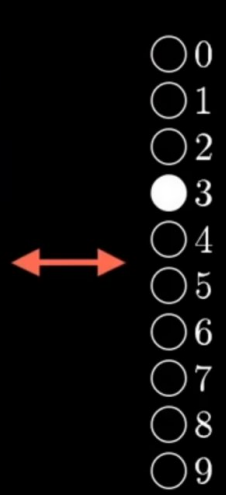
0
1
2
3
4
5
6
7
8
9

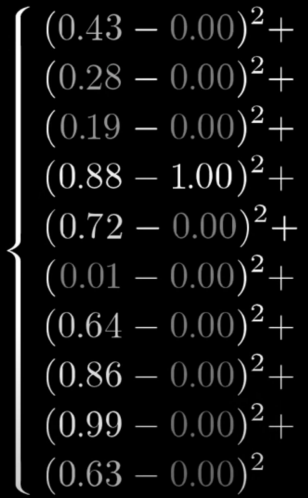
$(0.43 - 0.00)^2 +$
$(0.28 - 0.00)^2 +$
$(0.19 - 0.00)^2 +$
$(0.88 - 1.00)^2 +$
$(0.72 - 0.00)^2 +$
$(0.01 - 0.00)^2 +$
$(0.64 - 0.00)^2 +$
$(0.86 - 0.00)^2 +$
$(0.99 - 0.00)^2 +$
$(0.63 - 0.00)^2$

# Cost function

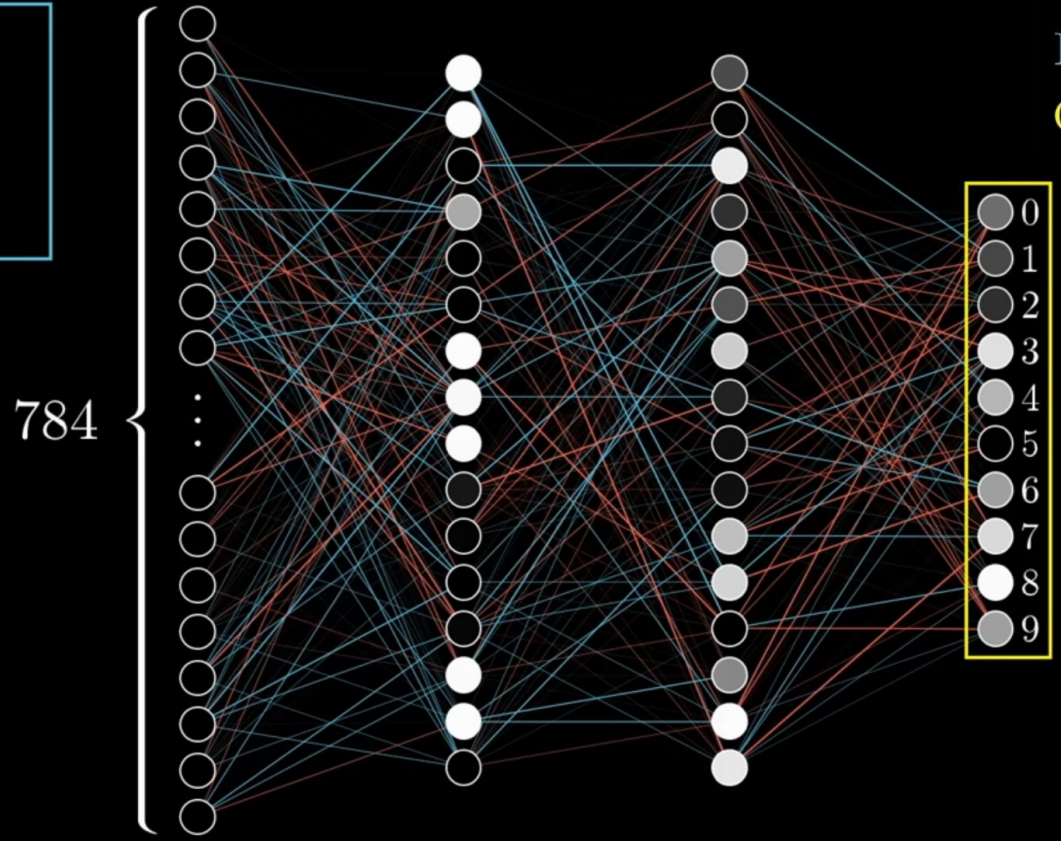


Input: 13,002 weights/biases

Output: 1 number (the cost)

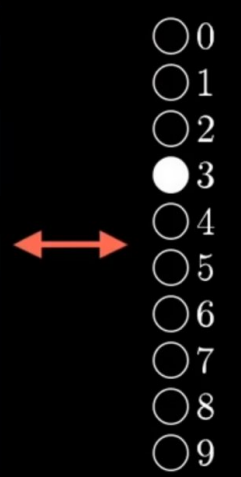


$$\begin{aligned}&(0.43-0.00)^2+\\&(0.28-0.00)^2+\\&(0.19-0.00)^2+\\&(0.88-1.00)^2+\\&(0.72-0.00)^2+\\&(0.01-0.00)^2+\\&(0.64-0.00)^2+\\&(0.86-0.00)^2+\\&(0.99-0.00)^2+\\&(0.63-0.00)^2\end{aligned}$$

$$J(a,b)=\frac{1}{2m}\sum_{i=1}^{m}\left(f(x^{(i)})-y^{(i)}\right)^2$$

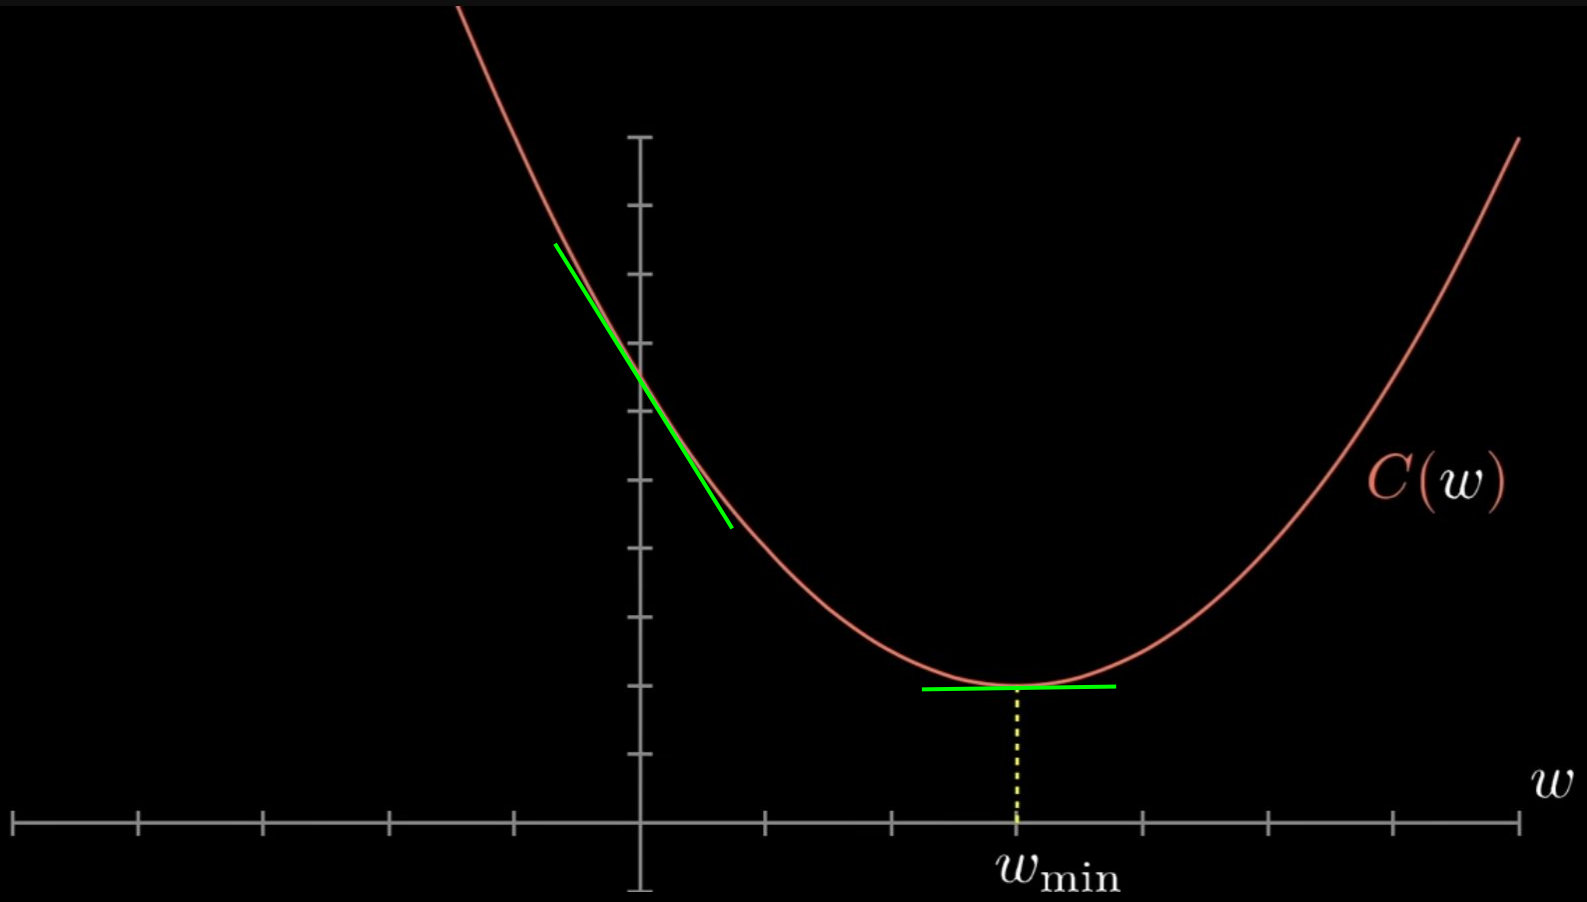
$C(w)$
$w$
$w_{\min}$

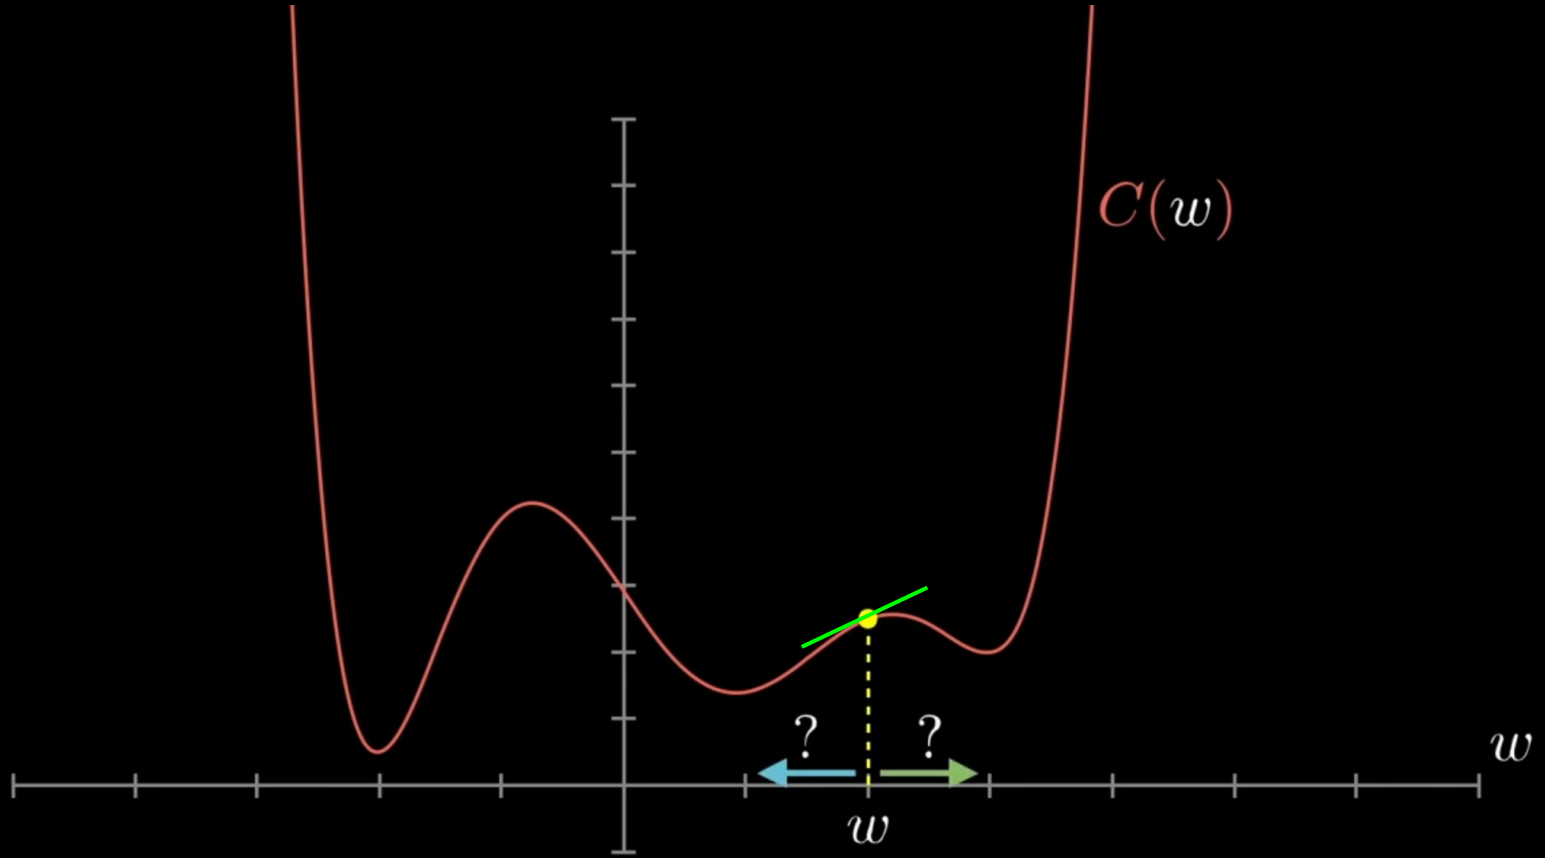
$C(w)$
?
?
$w$
$w$

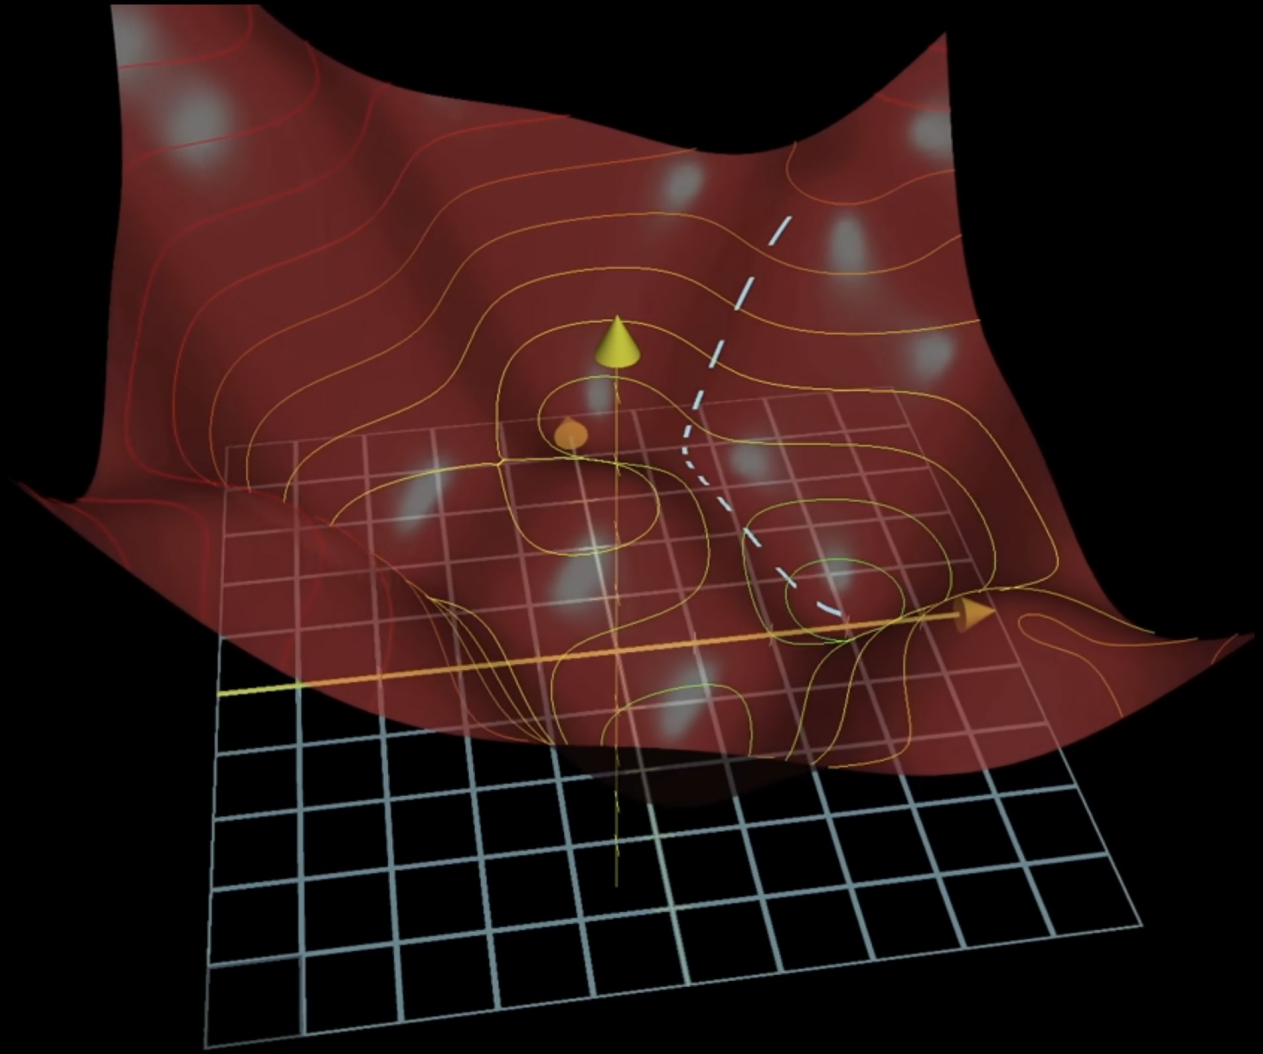

# (BATCH) GD

La rétropropagation est l'algorithme permettant de déterminer comment un seul exemple d'entraînement devrait pousser les poids pour provoquer la diminution la plus rapide de la fonction coût.

Une véritable étape de GD consisterait à faire cela pour tous les exemples d'entraînement et à faire la moyenne des changements souhaités que vous obtenez, à chaque étape de la Descente de Gradient ! C'est pourquoi l'algorithme est appelé Batch Gradient Descent : il utilise le lot entier de données d'entraînement à chaque étape. En conséquence, il est terriblement lent sur les très grands ensembles d'entraînement.

# STOCHASTIC GD

À l'extrême opposé, la méthode Stochastic Gradient Descent choisit une instance aléatoire dans l'ensemble d'entraînement à chaque étape et calcule les gradients en se basant uniquement sur cette instance unique.

Il est évident que le fait de travailler avec une seule instance à la fois rend l'algorithme beaucoup plus rapide, car il ne dispose que de très peu de données à manipuler à chaque itération.

En raison de sa nature stochastique (c'est-à-dire aléatoire), cet algorithme est beaucoup moins régulier que batch GD : au lieu de diminuer doucement jusqu'à atteindre le minimum, la fonction de coût rebondit de haut en bas, ne diminuant qu'en moyenne.

# MINI BATCH GD

A chaque étape, au lieu de calculer les gradients sur la base de l'ensemble complet d'entraînement (comme dans Batch GD) ou sur la base d'une seule instance (comme dans Stochastic GD), Mini-batch GD calcule les gradients sur de petits ensembles aléatoires d'instances appelés mini-batch.

Le principal avantage de Minibatch GD par rapport à Stochastic GD est qu'on peut obtenir une augmentation des performances grâce à l'optimisation matérielle des opérations matricielles via des GPU.

Minibatch GD finira par se rapprocher un peu plus du minimum que GD stochastique - mais il peut être plus difficile pour lui d'échapper aux minima locaux

# GD

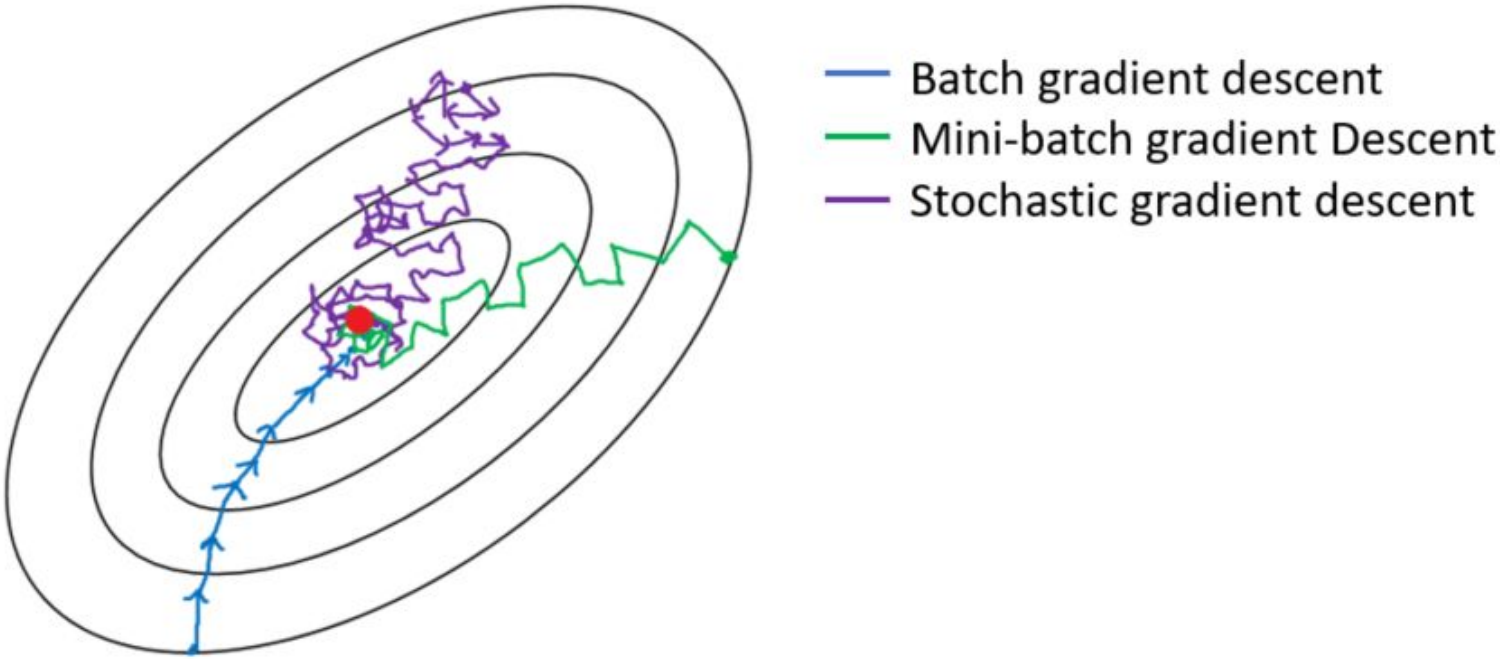
Batch gradient descent
Mini-batch gradient Descent
Stochastic gradient descent

# GD

Les fonctions de coût ne ressemblent pas tous à de beaux bols ordinaires (convexes).

Si l'initialisation aléatoire démarre l'algorithme à gauche, alors il convergera vers un minimum local, qui n'est pas aussi bon que le minimum global. Si elle démarre à droite, alors il faudra beaucoup de temps pour traverser le plateau. Et si on s’arrête trop tôt, on n'atteindra jamais le minimum global.

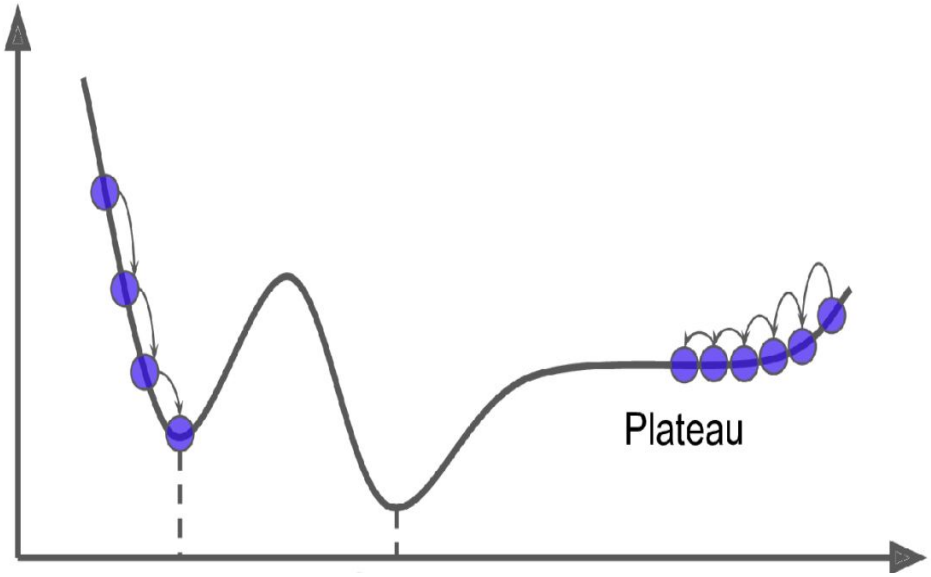

# FEATURES SCALING

Avant d’utiliser GD, il faut s’assurer que toutes les caractéristiques (features) ont une échelle similaire (par exemple, âge entre 0-70 et distance entre 1 et 100000 km), sinon la convergence prendra beaucoup plus de temps.

En fait, la fonction de coût a la forme d'un bol, mais il peut s'agir d'un bol allongé si les caractéristiques ont des échelles très différentes.

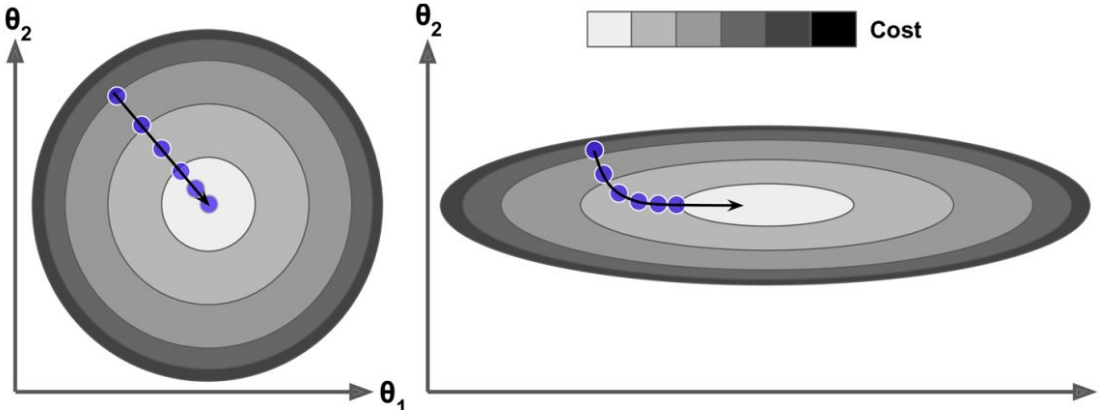

# LEARNING RATE

Concrètement, on commence l'entraînement d'un NN par remplir W avec des valeurs aléatoires (c'est ce qu'on appelle l'initialisation aléatoire).

Ensuite, nous l'améliorerons progressivement, en faisant un pas à la fois, chaque pas tentant de diminuer la fonction de coût, jusqu'à ce que l'algorithme converge vers un minimum.

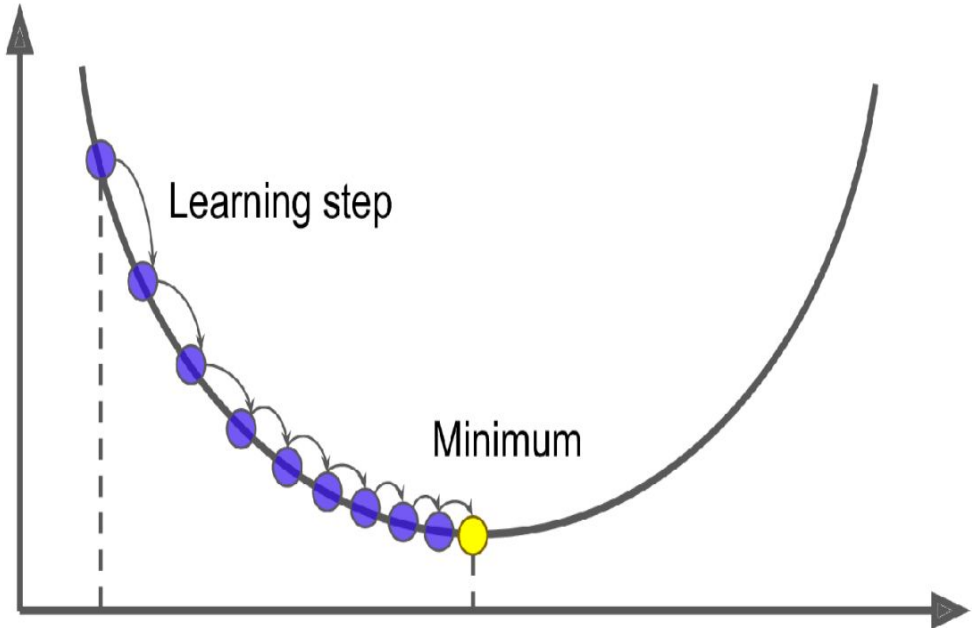

# LEARNING RATE

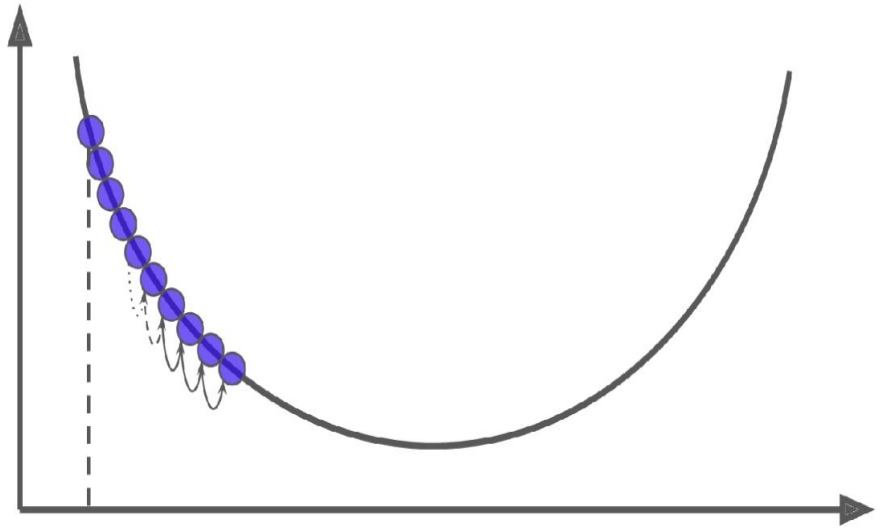

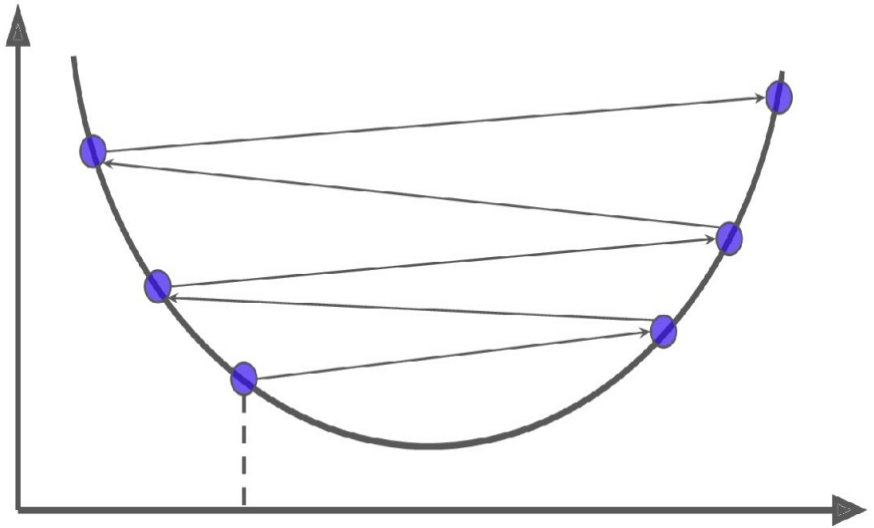

# GD + MOMENTUM

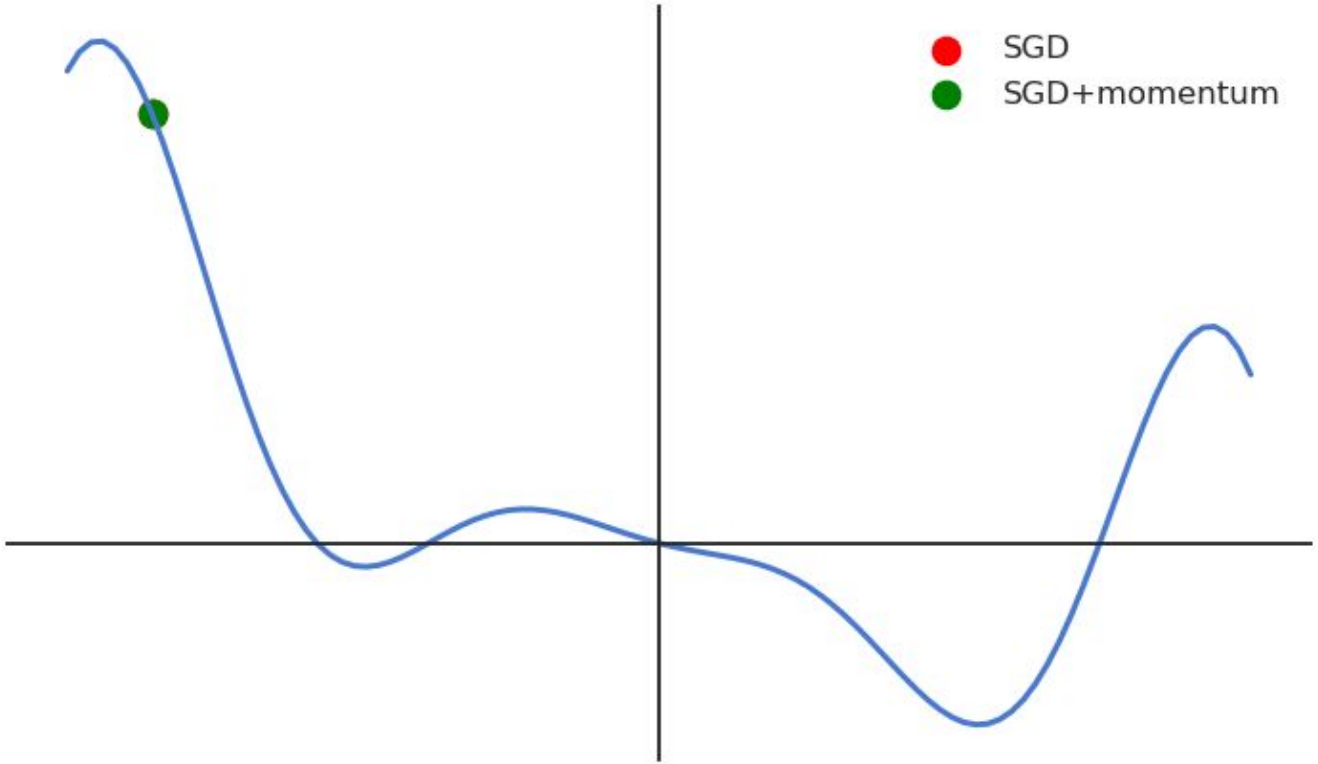


La descente de gradient avec momentum utilise la mémoire des gradients antérieurs pour lisser et accélérer la convergence.

# RMSPROP

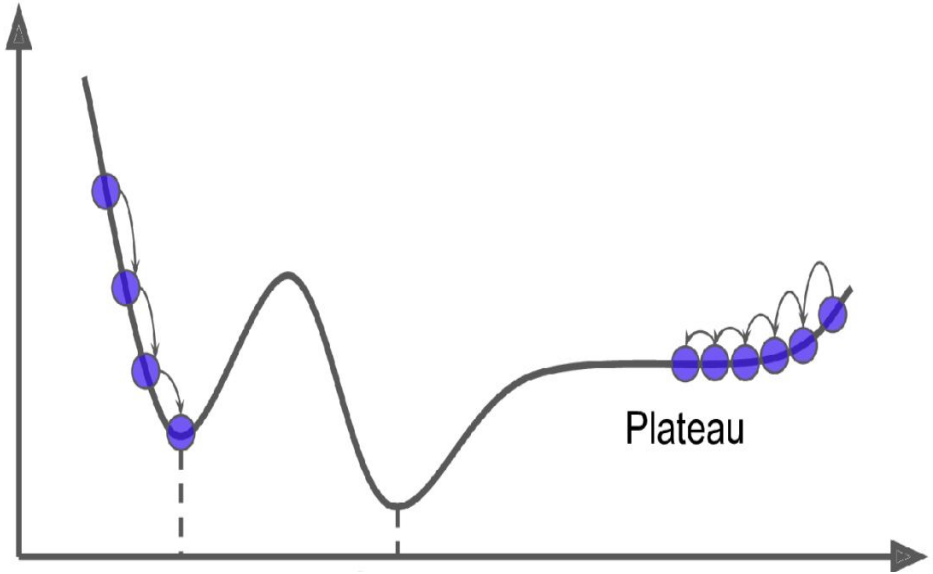


RMSProp adapte la taille des mises à jour en fonction de l'ampleur des gradients récents, ce qui permet d'éviter de trop dépasser la cible lorsque ces gradients sont élevés, et de ne pas s'immobiliser lorsqu'ils sont faibles.

# ADAM

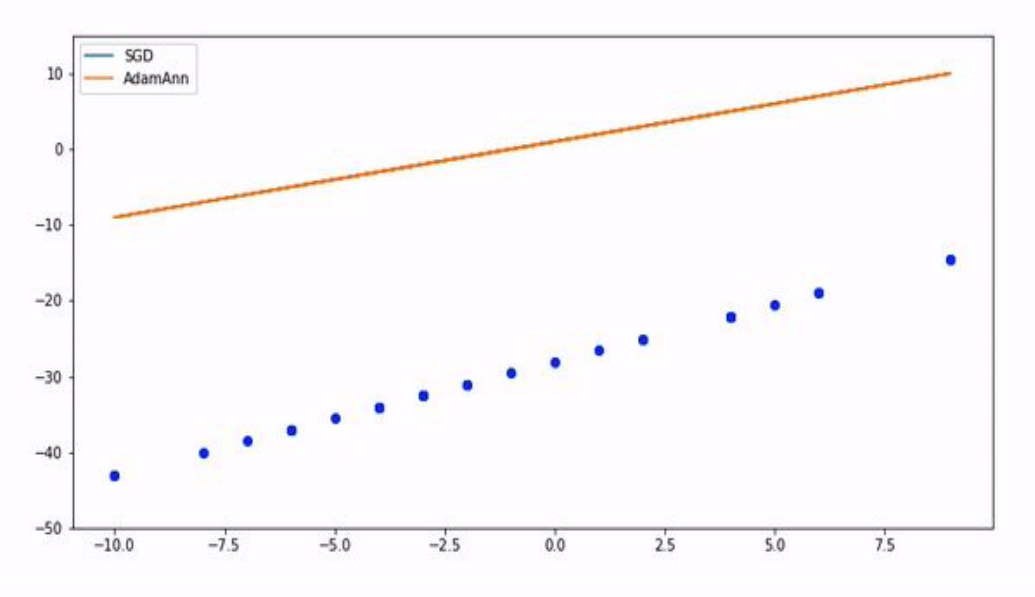


Adam est une méthode d'optimisation qui combine les avantages du momentum et de RMSProp. Elle conserve une moyenne mobile des gradients (comme le momentum) pour assurer la stabilité et l'orientation, et enregistre également une moyenne mobile des gradients au carré (comme RMSProp) afin d'adapter le taux d'apprentissage à l'échelle des paramètres. Cette approche duale aboutit souvent à une convergence plus rapide et plus fiable que l'utilisation d'une seule de ces méthodes.