ECOLE MAROCAINE DES SCIENCES DE L'INGENIEUR
Membre de
HONORIS UNITED UNIVERSITIES

INTRODUCTION AUX TRANSFORMERS ET LLMS

Aissam Outchakoucht

a.outchakoucht@emsi-edu.ma
aissam.outchakoucht@gmail.com

RECAP

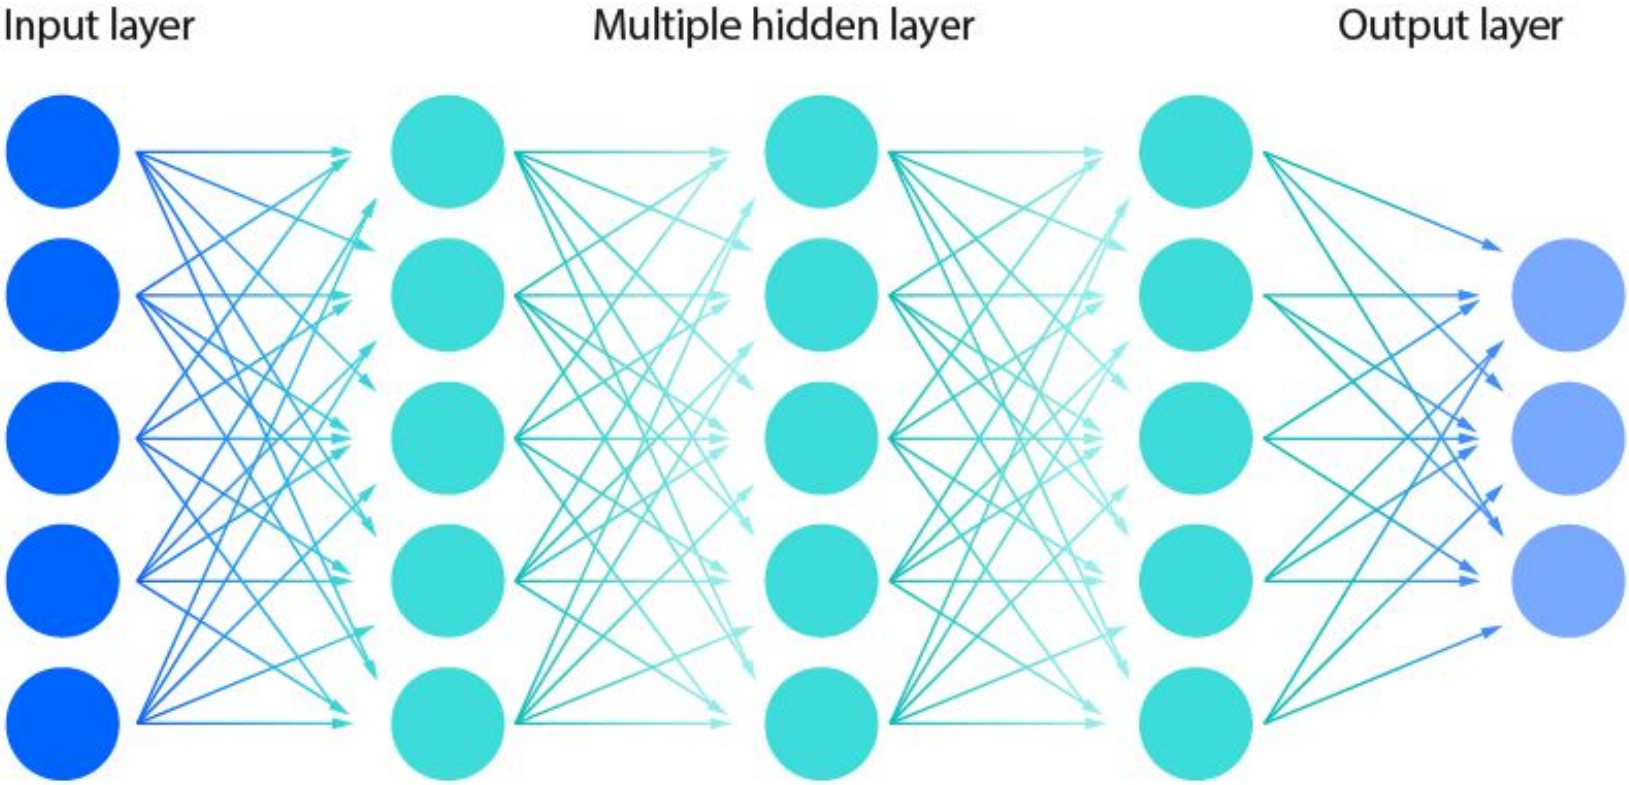

RECAP: CNN

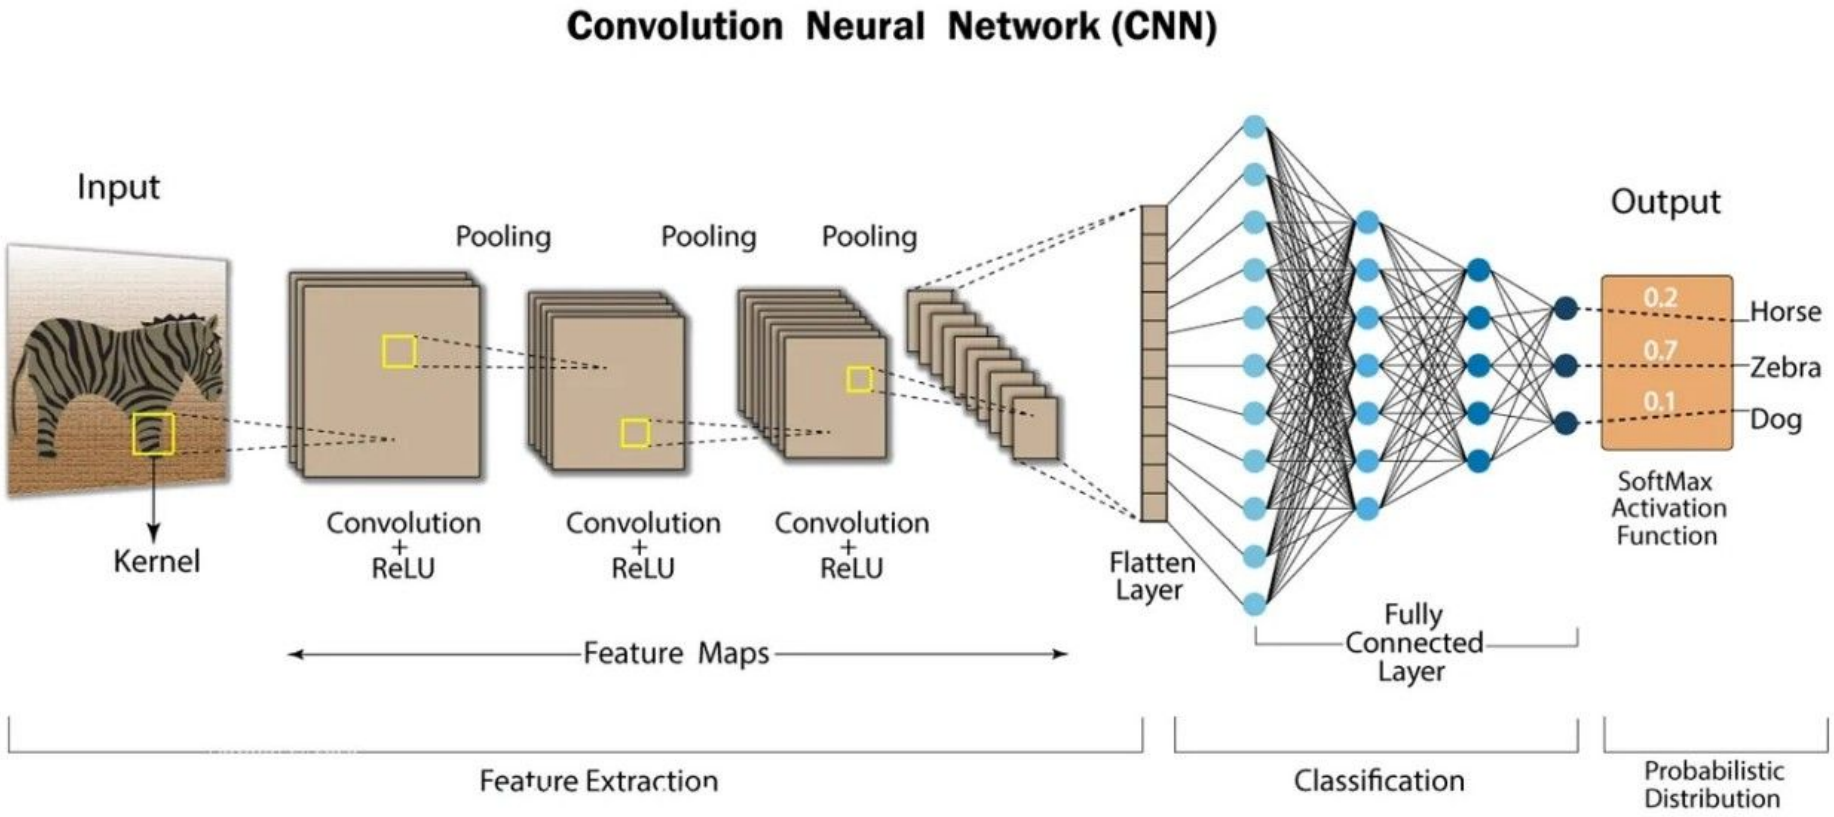
Convolution Neural Network (CNN)
Input
Kernel
Convolution + ReLU
Pooling
Convolution + ReLU
Pooling
Convolution + ReLU
Pooling
Feature Maps
Flatten Layer
Fully Connected Layer
Output
0.2
0.7
0.1
Horse
Zebra
Dog
SoftMax Activation Function
Feature Extraction
Classification
Probabilistic Distribution

RECAP: RNN

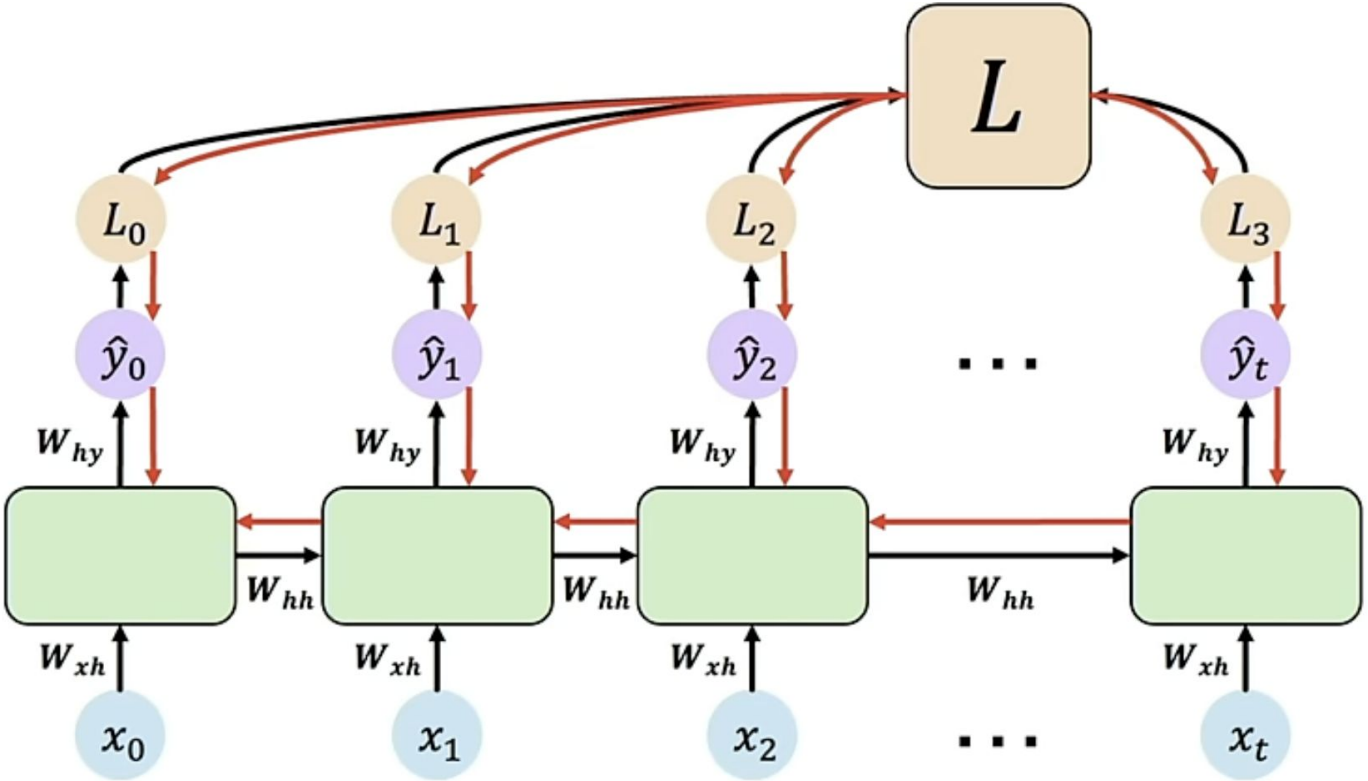

TOKENIZATION

hello world! this is a tokenization example

[24912, 2375, 0, 495, 382, 261, 6602, 2860, 4994]

```
from transformers import AutoTokenizer

tokenizer = AutoTokenizer.from_pretrained("bert-base-uncased")
tokens = tokenizer.tokenize("I love playing tennis.")
```

TOKENIZATION

hello world! this is a tokenization example

[24912, 2375, 0, 495, 382, 261, 6602, 2860, 4994]

```
from transformers import AutoTokenizer

tokenizer = AutoTokenizer.from_pretrained("bert-base-uncased")
tokens = tokenizer.tokenize("I love playing tennis.")
```

La tokenization est le processus de découpage d'un texte en unités plus petites appelées tokens.

TOKENIZATION

Caractéristique	Lettres	Mots	Sous-mots
Taille du vocabulaire	Petite	Grande	Moyenne
Longueur des séquences	Longue	Courte	Moyenne
Gestion des mots OOV	Excellente	Faible	Très bonne
Contexte sémantique	Faible	Fort	Moyen
Simplicité du prétraitement	Très simple	Moyenne	Complexe

EMBEDDING

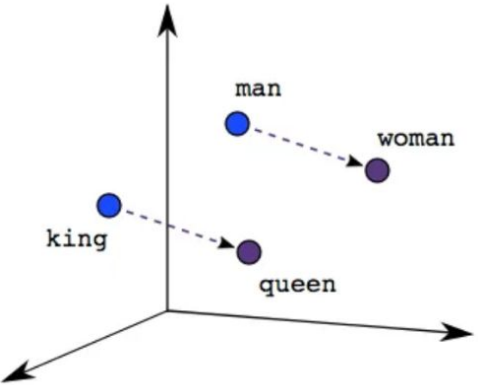

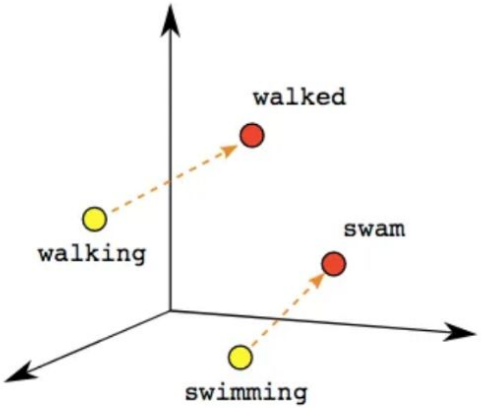

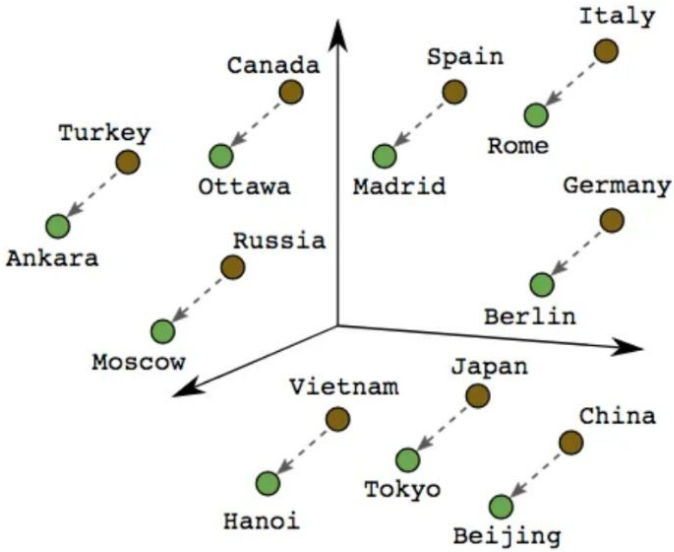

Un embedding est une représentation vectorielle d'un mot ou d'un token dans un espace multidimensionnel. Il permet de transformer chaque mot/token en un vecteur de nombres réels qui capture ses propriétés sémantiques et contextuelles.

NEXT WORD PREDICTION

?

Le soleil se lève à l’est et se couche à

TRANSFORMERS

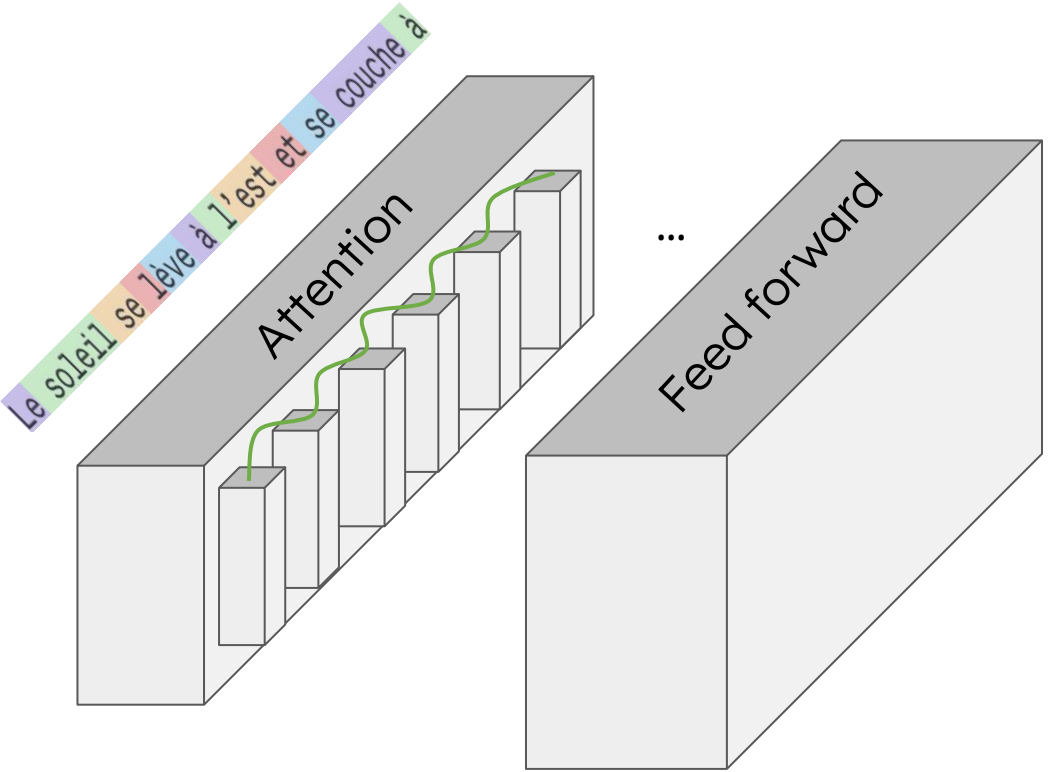

len=vocab size

0.3		0.01
9.2		0.87
2.2	softmax	0.1
. . .		. . .
1.2		0.001

Lookup l'ouest

⅓ of the params

⅔ of the params

TRANSFORMERS: ATTENTION

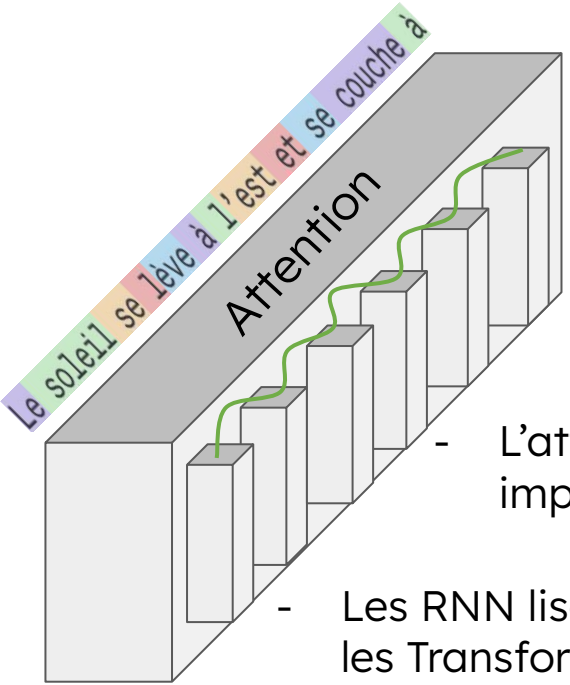

- Dans une phrase longue, certains mots sont plus importants que d'autres pour comprendre le contexte.
- Les modèles traditionnels (comme les RNN) ont du mal à se souvenir d'informations éloignées dans une séquence.
- L'attention permet au modèle de se concentrer sur les mots importants pour chaque mot de la phrase, même s'ils sont éloignés.
- Les RNN lisent mot par mot et oublient souvent les mots lointains, alors que les Transformers analysent tous les mots en même temps grâce à l'attention.

TRANSFORMERS: ATTENTION

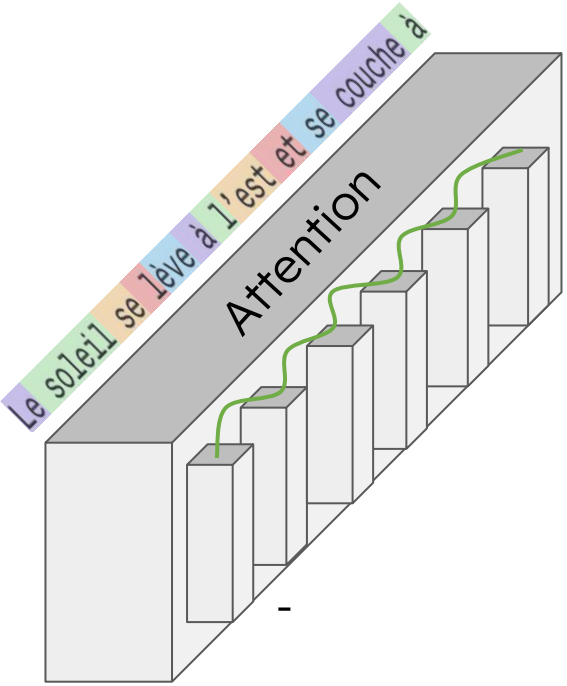

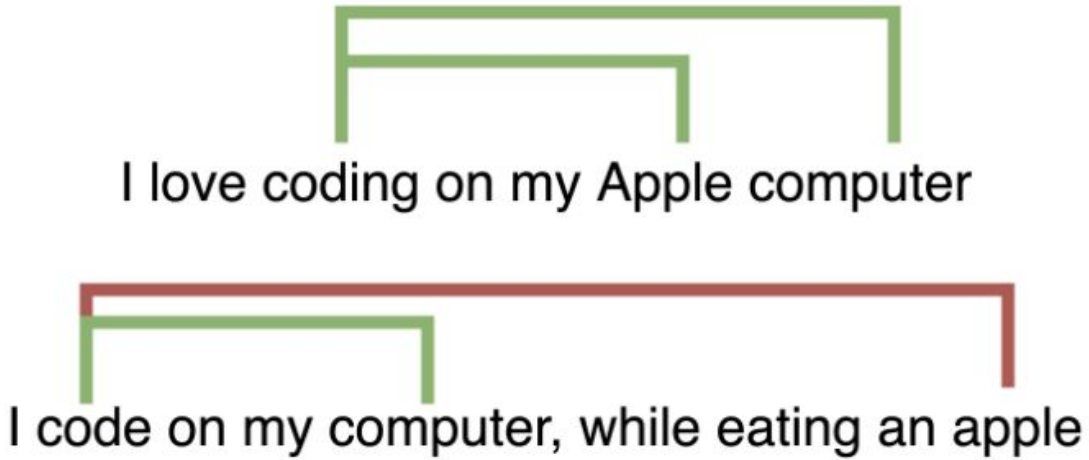

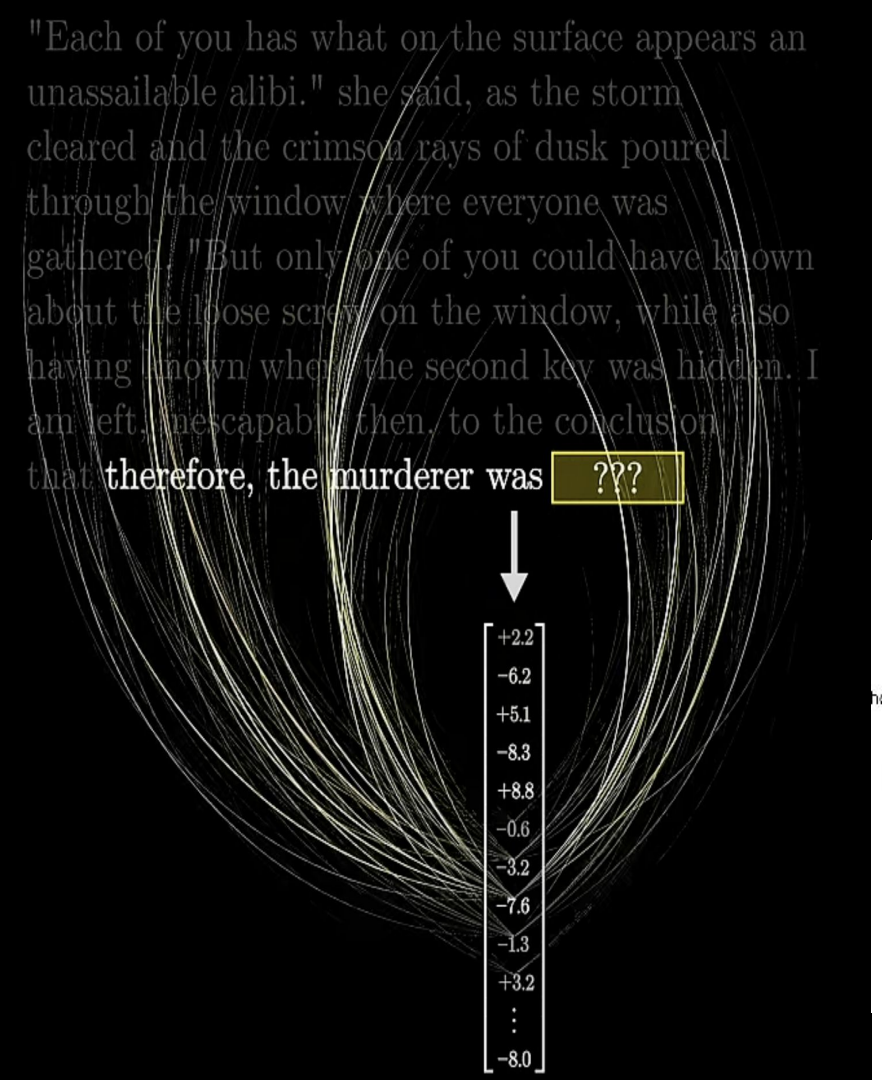

Le mécanisme d'attention est une technique utilisée dans les modèles de langage pour aider à se concentrer sur les parties importantes d'une phrase. Lorsqu'un mot est analysé, l'attention permet au modèle de "regarder" les autres mots pertinents, même s'ils sont éloignés dans la phrase. Cela aide à mieux comprendre le contexte et les relations entre les mots.

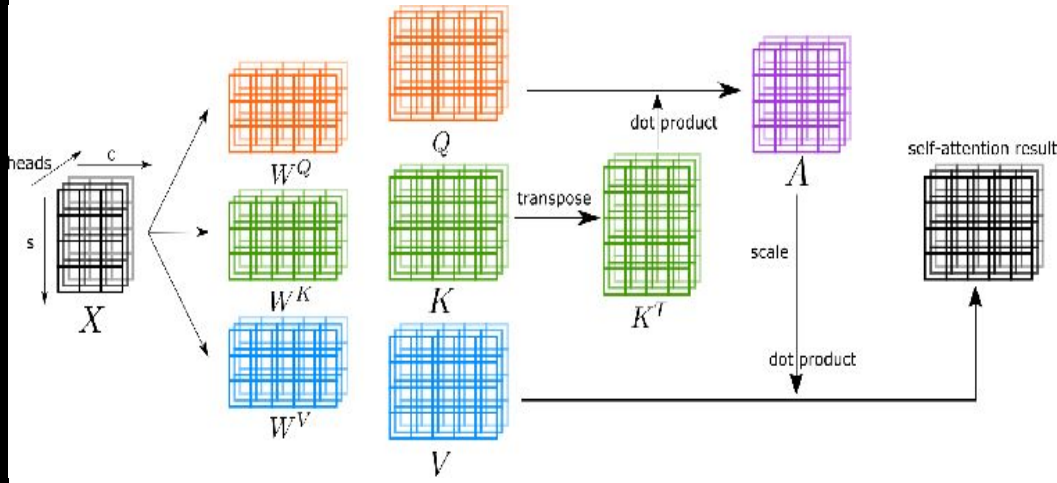

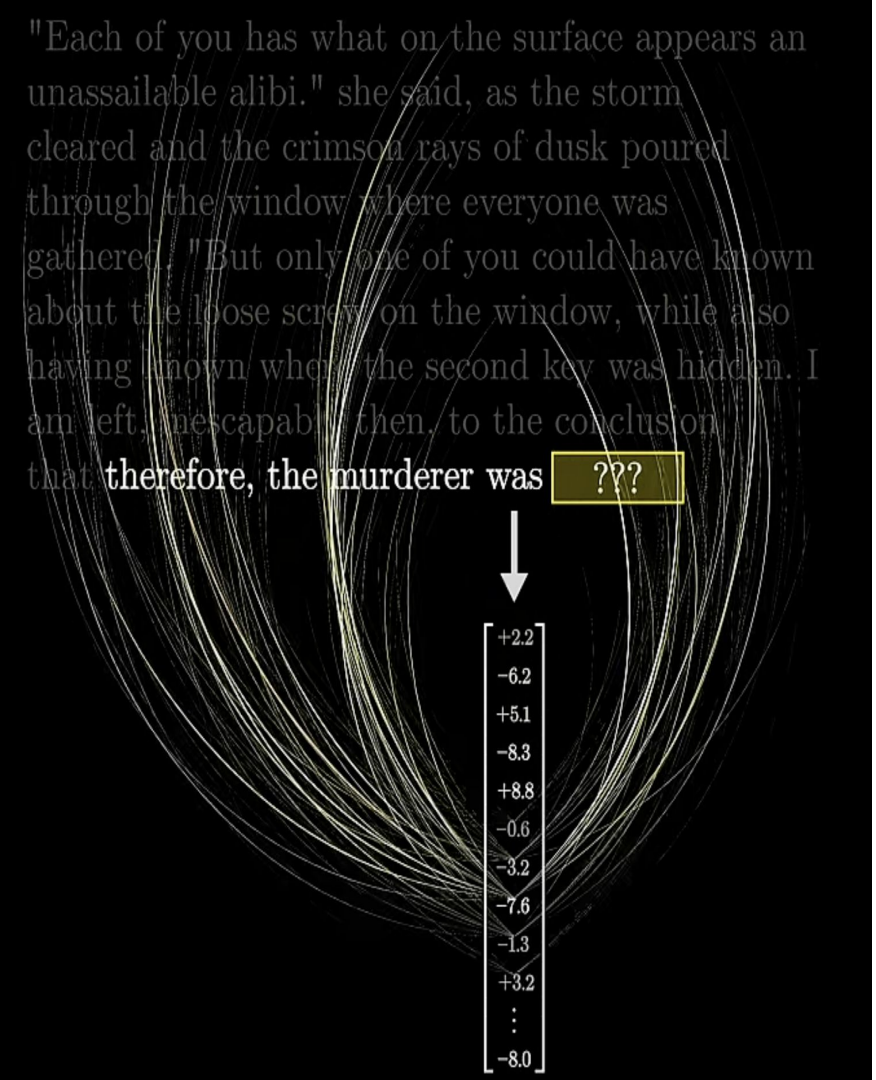

Le mécanisme d'attention est une technique utilisée dans les modèles de langage pour aider à se concentrer sur les parties importantes d'une phrase. Lorsqu'un mot est analysé, l'attention permet au modèle de "regarder" les autres mots pertinents, même s'ils sont éloignés dans la phrase. Cela aide à mieux comprendre le contexte et les relations entre les mots.

Query (Q) : Chaque mot pose une question pour savoir quels autres mots sont importants pour lui.

Key (K) : Chaque mot donne des indices pour montrer son importance.

Value (V) : Chaque mot apporte son contenu si on le considère important.

TRANSFORMERS: FEED FORWARD

Le feed forward agit comme une "mémoire" où le modèle stocke et traite les connaissances générales ou "faits" appris pendant l'entraînement.

Il transforme la sortie du mécanisme d'attention en une représentation plus utile, combinant les relations contextuelles captées par l'attention avec des modèles plus complexes.

Contrairement à l'attention qui traite les interactions entre les tokens, le feed forward fonctionne indépendamment sur chaque token, permettant d'affiner leur représentation individuelle.

Il affine les vecteurs d'entrée des tokens (issus de l'attention) en extrayant des caractéristiques plus abstraites et riches grâce à ses couches non-linéaires et ses activations (comme ReLU ou GELU).

Il projette les représentations des tokens dans un espace de dimension plus élevée (par exemple, un facteur de 4x la dimension d'entrée), ce qui permet d'apprendre des motifs plus abstraits. Ensuite, il réduit la dimension pour ramener les représentations à la taille d'origine.

TRANSFORMERS

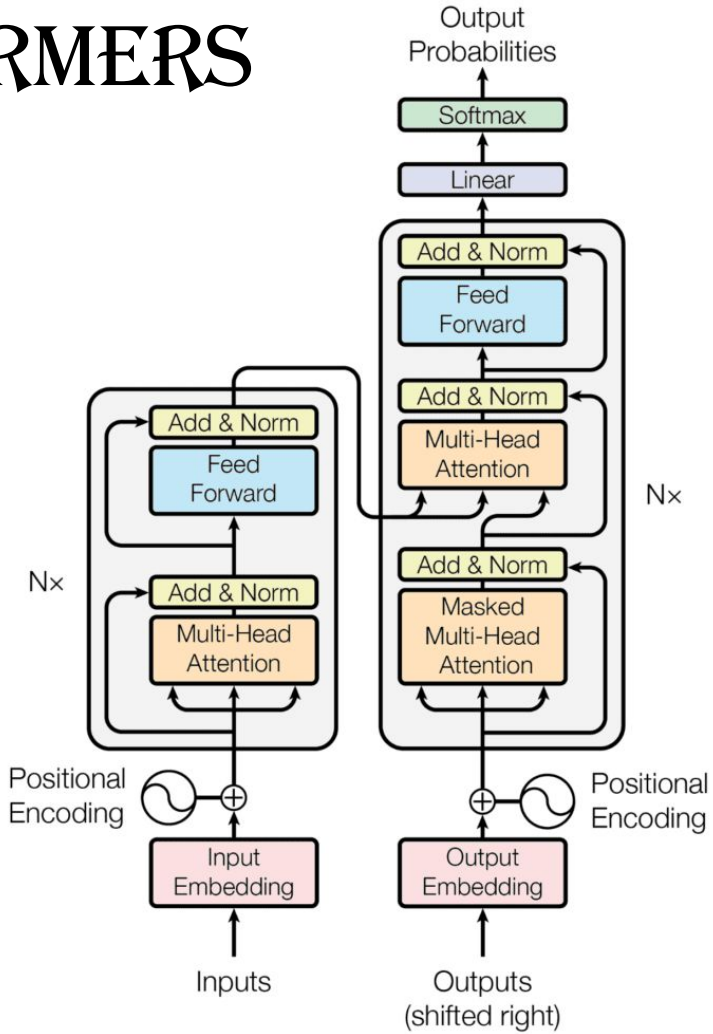

CONTEXT LENGTH

Model	Context length	Number of English pages*
GPT 3.5	4,096	6
GPT 4	8,192	12
GPT 4-32k	32,768	49
Llama 1	2,048	3
Llama 2	4,096	6

Context length comparison. (*Assuming 500 words per page.)

C'est le nombre maximum de mots ou tokens qu'un modèle peut traiter en même temps.

Avec un contexte limité, le modèle oublie les informations des débuts de texte lorsqu'il atteint la limite.

Augmenter la longueur du contexte rend les modèles plus lents et demande plus de mémoire.

TEMPERATURE

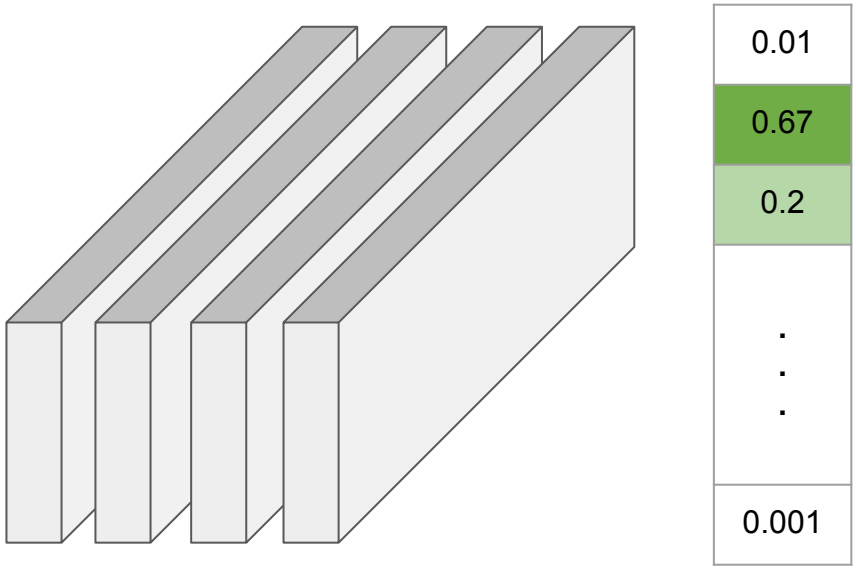

Un paramètre qui contrôle “la créativité” du modèle en ajustant la distribution de probabilité des mots générés.

Température basse : Génère des sorties plus précises et prévisibles en privilégiant les mots les plus probables.

Température élevée : Favorise des sorties plus variées et créatives en explorant des mots moins probables.